

图神经网络在推荐系统中的多场景应用综述

邢星*, 刘嘉雯, 王天池, 王鸿达, 贾志淳

(渤海大学 信息科学与技术学院 辽宁 锦州 121013)

摘要: 推荐系统能够快速有效地从纷繁复杂的数据中获取有价值的信息.传统推荐在新用户和新项目方面受限,数据稀缺导致推荐困难.同时忽视用户兴趣演化.鉴于传统推荐方法在面对复杂、大规模和动态变化的推荐场景下存在局限性,图神经网络技术引发了学术界的广泛关注.图神经网络在处理图数据和复杂交互关系方面具有优势,并且能够提高推荐的个性化、可解释性和时效性.图神经网络基于图结构数据和节点之间的交互关系,利用节点的特征和邻居信息进行推荐,提高了推荐的准确性.首先,介绍了图神经网络的基本原理和常用模型.其次,分析当前图神经网络在推荐中面临的问题,探讨应对方法.最后,按照不同推荐场景进行划分,对现有研究中的应对方法进行分类归纳.

关键词: 推荐系统; 图神经网络; 推荐场景

中图分类号: TP391

文献标识码: A

文章编号: 1673-0569(2023)04-0368-08

DOI:10.13831/j.cnki.issn.1673-0569.2023.04.004

0 引言

随着互联网空间中各类应用的层出不穷,海量信息源每天产生庞大数据量,经过多种渠道传递,进一步增加了信息的复杂性和多样性.面对众多信息源,往往导致人们选择困难和焦虑,即使能够处理信息数据,也只能接收到信息的碎片.推荐系统(recommendation system, RS)的出现缓解了信息过载带来的困境.通过个性化的推荐和过滤机制,使用户高效地获取信息,减少认知负担节省时间,提供多样化的内容选择,增加用户满意度并提高信息质量和可信度.在推荐应用程序中,交互数据可以使用二部图进行表示,用户行为序列也可以构建成图.因此,图结构在推荐系统中扮演着重要角色,能够更好地理解用户行为和项目属性.图神经网络(graph neural network, GNN)在处理图数据方向有很强的能力,通过分析图结构中节点和边,能够捕捉到用户和物品之间复杂的交互模式和关系,并且学习节点的表征向量,从而发现用户兴趣及偏好.此外,相比于传统的推荐系统而言, GNN 可以通过学习图结构中节点之间的传播路径,捕捉到隐式的关系和影响.在推荐系统中使用 GNN 能够最大化地处理非欧式数据,提高推荐结果质量.本文将对基于 GNN 推荐系统的研究进行深入探讨,主要关注方法和问题两大核心内容.在方法方面,将探讨各种图神经网络模型在推荐系统中的应用,分析其原理和优势.在问题方面,分析图神经网络在用户项目二部图面临的困难,寻找应对方法,并总结不同推荐场景下的详细信息.

1 基于图神经网络的推荐系统

基于图神经网络的推荐系统利用节点和边的关系,能够深入挖掘用户和物品之间复杂的关系,包括隐性交互和社交关系,从而更准确地理解用户的兴趣.它不仅考虑了用户和物品直接交互,还能利用邻居节点信息,从全局网络结构中获取有用的信息.同时,能够处理高维稀疏的数据,并能够根据用户的不

收稿日期: 2023-08-08.

基金项目: 国家自然科学基金项目(No: 61972053; No: 62172057); 辽宁省教育厅科研项目(No: 2022JH2/101300281); 辽宁省应用基础研究发展计划项目(No: 2022JH2/101300281); 辽宁“百千万人才工程”A类项目培养经费资助(No: 2021921024).

作者简介: 邢星(1982-),男,博士,教授,“CCF 高级会员(84476S)”,主要从事机器学习、推荐系统方面的研究.

通信作者: xingxing@bhu.edu.cn.

同需求提供个性化、多样化的推荐结果.图神经网络主要原理^[1]是通过迭代的方式更新节点的表示,将节点信息融入到节点自身的表示中,实现对图结构数据的深度学习,最终通过某种特定的方式输出这些节点的表示形式,获得最终所需信息.

图卷积网络(graph convolution networks, GCN)^[2]从传统数据推广到图数据中,通过特征传播和层级传播的方式,融合图中节点的全局和局部信息,丰富节点特征向量表示.Chen等^[3]在GCN能够对图数据进行建模和分析,并通过多层卷积操作高效提取图数据的特征表示的基础上,探讨了在混合计算-内存体系结构上部署GCNs的方法,以提高计算和存储效率,减少数据传输和存取开销,并提高GCNs的性能和能耗效率.文献[4]通过GCN处理大规模推荐系统中的图数据,提高了传统推荐系统的准确性和效率.在网页规模的推荐系统中取得了显著改进,有效地捕捉了用户和物品之间的复杂关系.

图注意力网络(graph attention networks, GAT)是一种基于空间的图卷积神经网络,对每对节点和邻居节点之间的关系分配一个注意力权重,自适应地学习节点之间的关系,并且能够处理复杂的图结构和上下文信息.GAT在保留有效信息的同时减少了信息的损失,提高了模型的性能和表达能力.Song等^[5]提出了一种基于动态图注意力网络的会话推荐系统(dynamic-graph-attention neural network),用于在线社区的信息推荐.该系统采用循环神经网络模型动态用户行为,采用图注意力网络学习基于用户当前兴趣的每个朋友的影响权重.Wu等^[6]提出了一种双图注意力网络(dual graph attention networks, DGAT),旨在捕捉推荐系统中用户之间的社交关系以及物品之间的联系,GAT通过利用多方面的社交效应和学习潜在表示来提高推荐系统的准确性和个性化程度.

异构图神经网络(heterogeneous graph neural networks, HetGNN)能够处理复杂的异构关系,首先将用户、物品和交互关系建模为一个异构图,通过引入不同类型节点之间的消息传递机制,自动学习节点之间的异构关系,每个节点都会根据它们的特征和邻居节点的特征来更新自身的表示,从而捕捉到节点之间的语义关联.Chen等^[7]提出了一个高效的基于会话的社交推荐框架,其包括用户-用户边、用户-项目边、项目-用户边和项目-项目边四种不同类型的边,他们使用HetGNN来学习用户和项目的表示,整合社交网络的信息.

超图神经网络(hyper graph neural networks, HGNN)能够在处理超图数据时捕获高阶和非二元关系.此外,它们可以有效地将超边缘信息传播到连接的节点.

2 GNN 推荐系统挑战

结合图神经网络和用户项目二部图时,如何整合用户项目二部图和图神经网络,怎样在图传播中采样具有代表性的邻域是难点.图神经网络直接应用于原始二部图中会出现原始图结构无法有效地学习用户项目表示.

Liu等^[8]将图神经网络和协同过滤相结合,将用户项目之间的相似性合并到用户项目交互中.文献[9]中借用图卷积矩阵补全的思想,通过从用户-项目二分图中提取空间信息获得用户-项目的表示,添加了用户和项目之间的边,同时利用附加的侧边信息,提高推荐系统的性能.Shafqat等^[10]通过对邻居进行采样,结合不同节点之间的相似性度量,降低计算复杂度.Huang等^[11]通过在用户-项目交互图中引入虚拟节点更好地理解用户和项目之间的交互模式,捕捉用户-物品之间的交互关系,更好地理解用户-项目交互关系中的负例,提高模型的准确性.Michael等^[12]引入关系特定变换,采用图剪枝的方法,通过稀疏矩阵乘法避免显式求和邻域,有效降低计算复杂度.采样方法适合用于大规模或动态网络中,只保留部分节点和边,而剪枝方法更适用于整个已知图中,剪除冗余的节点和边,简化图结构,两者都能提高信息传播效率.

在邻居聚合过程中,辨别邻居是否重要,以便决定建立中心节点与邻居节点亲和力模型还是邻居交互模型.William等^[13]使用了平均池化来对邻居进行聚合,将一个区域的多个样本的特征值进行平均计

算,以生成一个代表该区域的单一特征值.平均池化在聚合过程中平等地对待邻居,平滑了相邻节点的信息.特征表示缺乏差异性.Wang 等^[14]在模型中引入了注意力机制,通过计算注意力权重,模型自动学习邻居节点对目标节点的重要性,并相应地进行加权聚合.文献[15]引入了跨类型注意力机制,允许不同类型的节点对邻居节点进行不同程度的关注和权重分配.还用了基于注意力的机制,能够自适应地关注和利用具有更大影响力的邻居节点,将其重要性纳入信息聚合的过程中.Gao 等^[16]使用注意力机制动态调整邻居节点的贡献,更好地捕捉用户间的同质性.平均池化适用于简单的图结构,方法简单有效;而注意力机制可以根据节点之间的关系自适应地学习权重,提高信息聚合的精度,但计算复杂度较高.

最终预测用户对项目的偏好需要综合整体的用户-项目表征.一些研究^[17-18]使用图神经网络最后一层中的节点向量作为最终表示.但是,不同层获得的表征代表通过不同的连接消息传递^[19],低层中的节点表示更加关注节点本身的特征,而较高层中的节点表示则更加关注节点与邻居节点之间的关系和相互作用.堆叠多个图神经网络层^[20]来实现信息传播,有助于捕捉远距离依赖,信息保留完整,信息增强节点表示.Kim 等^[21]通过对每个卷积核提取的特征映射执行最大池化操作得到最终节点表示.最大池化保留了最显著的特征信息,降低计算复杂度,但是会忽略其他邻居节点.SGCN 模型^[22]通过正边权池化和负边权池化,将正邻居节点特征和负邻居节点特征分别进行加权聚合,并将结果传递给正边权卷积和负边权卷积层,获得更准确的节点表示.加权池化则充分利用了边权信息,能够更准确地反映节点在表示中的贡献度.

3 不同推荐场景下的研究现状

3.1 会话推荐

“会话”通常由用户在一次在线交互中的多个连续操作组成,如浏览商品、搜索、点击等一段时间内的连续性行为序列.这些操作按照时间顺序排列,能够反应用户在某段时间内的兴趣变化.在实际情境中,用户对于选择物品的决策不仅受其长期的喜好影响,还受到对时间敏感的短期偏好的影响.

在会话推荐中,如何建模会话数据中的项目转换模式和如何从杂乱的数据中提取仅基于会话的特征是有待解决的问题,以支持更准确的推荐.Ding 等^[23]用超图神经网络捕捉项目之间的相关性,发现相似会话之间的兴趣模式,通过图注意力网络聚合相似会话之间的信息.Zhou 等^[24]使用图神经网络来嵌入这个项目的动态图,并学习由时间增强的项目表示.它用每天的数据构建一个对应图表,用来模拟项目之间的关系.同一项目在不同的日子可能有不同的邻居,展示了用户兴趣的转移.添加会话图的附加边,使会话图所包含的信息更加丰富.Zhang 等^[25]提出个性化图卷积网络来捕获项目之间的复杂转换,获取项目之间的长期依赖关系来增强会话图.MKM-SR 模型^[26]引入序列建模捕获项目转换,通过特定行为模型考虑用户微观行为,并结合项目转换和项目知识整合到会话推荐的多任务学习中,进一步增强给定会话中的信息.COTREC 模型^[27]对项目图和折线图使用 GCN,分别从项目视图和会话视图中获取信息.DESIGN 模型^[28]在有向社交图中使用图卷积计算用户不同社交关系的影响.GAT 应用重点是注意力机制.SHARE 模型^[29]在会话超图上使用 GAT,以捕获项目之间的高阶关系.基于 GNN 会话推荐模型信息在表 1 中做了汇总.

表 1 会话推荐中图神经网络的详细信息

算法名称	图	图神经网络类型	方法
HGNNA ^[23]	超图	超图神经网络	注意力机制
TASRec ^[24]	动态图	图卷积神经网络	加权平均
MKM-SR ^[26]	有向图	门控图神经网络	用 MTL 范式实现知识嵌入
CONTREC ^[27]	项目图+折线图	图卷积神经网络	附加边
DESIGN ^[28]	有向图	图卷积神经网络	附加边
SHARE ^[29]	会话超图	图注意力神经网络	附加边

3.2 捆绑推荐

基于用户行为和偏好的算法,旨在通过将相关的产品或内容捆绑在一起,同时向用户提供一组相关联的物品或服务,提供给用户更加个性化和具有吸引力的推荐选择,以满足用户的多样化需求.在个性化场景中,捆绑销售是一种极为重要的推广营销策略,将相关的商品组合在一起,以吸引用户购买整个组合而不是单个商品^[30].这种策略不仅可以提升用户体验,减少购物的单调感,还能为商家带来更多的销售机会.常见捆绑的策略有完全混合捆绑、部分混合捆绑和纯捆绑^[31].选择合适的捆绑策略至关重要,不合适的策略可能导致用户对推荐结果感到不满,减少购买兴趣甚至流失^[32].

将图神经网络应用于捆绑推荐需要解决项目组成、稀疏表示和高阶关系三个挑战.首先,需要解决捆绑包中项目组成问题;其次,要学习具有用户-捆绑包交互的稀疏表示;最后,获取用户项目之间的高阶关系.GRAM-SMOT模型^[33]构建用户-项目二部图,利用图注意力机制允许模型自动地关注重要的节点和边,捕捉复杂的用户与项目交互关系.同时,还采用次模优化策略,在给定用户和候选项目的情况下,考虑项目之间的互补性、多样性和用户偏好基础上,选择出最合适的一组项目组成捆绑包.Zhao等^[34]采用多视图学习的方法来处理用户与捆绑包之间不同视图的特征表示,通过多层图卷积神经网络来学习用户和捆绑包在图结构上的表达.Wang等^[35]使用关系图神经网络解决了捆绑推荐中的项目组成问题,引入邻居交互机制帮助模型获取用户-项目之间的高阶关系.DPR模型^[36]根据用户的历史购买记录以及和药品的交互行为,生成一个交互感知的图结构.该图结构能够刻画用户项目之间的高阶关系,从而更好地理解不同药品之间的关联性.基于GNN捆绑推荐模型信息在表2中做了汇总.

表2 捆绑推荐中图神经网络的详细信息

算法名称	图嵌入	图神经网络类型	方法
GRAM-SMOT ^[33]	用户-项目捆绑图	图注意力网络	注意力机制
MIDGN ^[34]	用户-项目捆绑图	异构图神经网络	权重、意图感知机
关系图神经网络 ^[35]	捆绑项目交互图+捆绑项目隶属图	图卷积神经网络	元素乘积
DPR ^[36]	层次结构图	图卷积神经网络	图归纳

3.3 多行为推荐

在现实推荐中,用户行为本质是多类型的,其中涉及用户与项目之间的异构关系^[37],如浏览、评级、购买等.每个用户的行为都可以传递不同的含义,反映出用户与项目之间的多样交互方式.准确地捕获各种用户行为之间的潜在关联是至关重要的,这些不同类型的交互行为以复杂的方式相互交织,为用户兴趣建模提供了宝贵的补充信息.

目前已有的多行为用户建模技术常用于推荐^[37],但在考虑不同用户-商品关系的情况下,往往难以捕捉到高阶关系.图神经网络推荐系统需要根据用户项目二部图构建不同类型的边,因此大多数基于图神经网络的多行为推荐方法都是基于异构图的.在多行为推荐建模中,主要挑战包括如何建立多个行为和目标行为之间的关系模型,以及如何准确地利用行为信息来表达项目的语义.Huang等^[38]在基于图的消息传递架构下,显式建模不同类型的用户-项目交互的依赖关系,并通过图卷积网络上的聚合机制,以明确建模不同类型行为的影响.Yu等^[39]考虑辅助行为数据对目标行为的影响,在嵌入传播层中,利用简化的图卷积网络来学习单个行为的用户表示和项目表示,分别计算用户对不同的单一行为的偏好.最后通过融合预测层来融合用户对各种行为的偏好.利用注意力机制为行为设置权重,Wei等^[40]计算行为权重矩阵,利用注意力机制进行信息聚合.除了建模不同类型行为的影响外,交互中不同行为代表了不同的语义.将这些项目通过图连接起来,可以增强项目的表示.为了获得更好的项目表示,Yu等^[41]不仅连接了图中的相关项目,还构建了项目所属类别的新图,用于增强项目的表示.基于GNN多行为推荐模型信息在表3中做了汇总.

表 3 多行为推荐中图神经网络的详细信息

算法名称	图嵌入	图神经网络类型	多行为建模方法
GNMR ^[38]	用户-项目图	图对抗神经网络	显示建模不同类型的依赖关系
SGCNMB ^[39]	用户-项目图	图卷积神经网络	权重
AMR ^[40]	用户-项目图	图注意力神经网络	权重
GNNH ^[41]	项目-项目图+类别-类别图	图卷积神经网络	自注意力、平均池化、权重

3.4 社交推荐

社交推荐是通过用户周围的人获取和传播信息的现象而开发的^[42].在这种系统中,用户的社交关系对于信息过滤起着重要作用,并且社交关系有助于提高推荐效果.构建社交推荐系统的关键是学习物品和用户的表示.社交推荐系统可以将社交网络信息融入到用户和项目的潜在因素学习中.通过利用本地邻居对社交网络中每个用户的偏好进行建模,社交推荐系统的目标是增强用户建模的准确性.

社交推荐的挑战之一是构建能捕捉用户高阶社会关系的社交图.用户不仅受朋友影响,也受朋友的朋友影响,最终行为由社会影响和个人偏好共同决定.具体来说,就是如何捕提高阶的社会关系.Guo 等^[43]通过将多个如神经网络堆叠在一起,利用多层感知机编码器通过逐渐堆叠隐藏层,可以逐渐提取出输入数据的特征表示.Yu 等^[44]使用可以连接两个以上节点的超边对高阶关系进行建模.KCGN 模型^[45]使用开发的知識感知耦合图来捕获用户-用户和项目-项目关系.如何结合好友的社交因素和用户的交互行为偏好是第二个面临的挑战.Yu 等^[46]采用邻域注意力权重计算来确定每个邻居节点的特征相似度和注意力加权平均聚合.GraphRec 模型^[47]利用邻居节点更新每个节点表示通过多层图卷积层堆叠提取更高层的特征信息,最后将多层图卷积层的输出作为最终表示.Zhang 等^[48]利用注意力机制计算注意力分数来调整邻居节点的特征表示,使得每个邻居节点的重要性根据其当前节点的相关性进行自适应调整,以更好地建模用户与其邻居之间的关系.基于 GNN 社交推荐模型信息在表 4 中做了汇总.

表 4 社交推荐中图神经网络的详细信息

算法名称	图嵌入	图神经网络类型	社会信号提取
GNN-SoR ^[43]	社交图+用户-项目图	图神经网络	串联
MHCN ^[44]	社交图	超图神经网络	超图卷积网络
KCGN ^[45]	社交图+项目依赖图	图神经网络	知识感知耦合图神经网络
ESRF ^[46]	用户图+用户-用户图+项目图	图卷积神经网络	注意力机制
GraphRec ^[47]	用用户-用户图+用户-项目图	图卷积神经网络	图神经网络
MG-HIF ^[48]	社交图	图对抗神经网络	多层注意力网络

4 总结与展望

相对于传统神经网络相比,图神经网络通过学习节点之间的关系,捕捉图数据中的拓扑结构和信息传递.随着图神经网络与推荐系统的紧密结合,推荐系统中的冷启动和数据稀疏等问题逐渐被克服.图神经网络是专门用于处理图结构数据的一种深度学习技术,加快了图数据分析的速度,适用于处理复杂关系的数据结构,已经适用于推荐系统之中.推荐系统在不断创新和演进中取得了显著的进步.本文从将图神经网络应用于用户项目二部图方面入手,针对面临的挑战和解决方法两个角度对图神经网络推荐系统进行分析,并且将相关研究按照不同的推荐场景进行梳理和总结.但是在未来研究中还存在以下研究困难:推荐系统中涉及信息变得广泛,形式多样,存在多模态信息融合问题;用户的行为具有时序性和动态性,由于时序信息分布的不均匀会使得模型在某些时间段内对用户行为敏感或不敏感,存在动态建模难以平衡问题;用户环境不断变化,行为也在不断的变化,在推荐系统中要实现在线学习和增量学

习的有效性,存在如何在动态图中设计出良好鲁棒性的在线学习算法.总而言之,这些难点不仅是未来研究的重要方向,同时也是需要深入探讨和解决的问题.解决这些挑战将为未来推荐系统的发展提供关键的方向和创新动力.

参考文献

- [1] 吴国栋,查志康,涂立静,等.图神经网络推荐研究进展[J].智能系统学报,2020,15(1):14-24.
- [2] 徐冰冰,岑科廷,黄俊杰,等.图卷积神经网络综述[J].计算机学报,2020,43(5):755-780.
- [3] CHEN J X, LIN G Q, CHEN J X, et al. Towards efficient allocation of graph convolutional networks on hybrid computation-in-memory architecture[J]. Science in China Series F: Information Sciences, 2021, 64(6): 108-121.
- [4] YING R, HE R N, CHEN K F, et al. Graph convolutional neural networks for web-scale recommender systems[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. London, United Kingdom. New York: ACM, 2018: 974-983.
- [5] SONG W P, XIAO Z P, WANG Y F, et al. Session-based social recommendation via dynamic graph attention networks[C]//Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining. Melbourne VIC, Australia. New York: ACM, 2019: 555-563.
- [6] WU Q T, ZHANG H R, GAO X F, et al. Dual graph attention networks for deep latent representation of multifaceted social effects in recommender systems[C]//WWW '19: The World Wide Web Conference. San Francisco, CA, USA. New York: ACM, 2019: 2091-2102.
- [7] CHEN T W, WONG R C W. An efficient and effective framework for session-based social recommendation[C]//Proceedings of the 14th ACM International Conference on Web Search and Data Mining. Virtual Event, Israel. New York: ACM, 2021: 400-408.
- [8] LIU H D, YANG B, LI D S. Graph collaborative filtering based on dual-message propagation mechanism[J]. IEEE Transactions on Cybernetics, 2023, 53(1): 352-364.
- [9] NIU K, YU Y C, CAO X P, et al. GCMCSR: a new graph convolution matrix complete method with side-information reconstruction[C]//2020 International Conference on Data Mining Workshops (ICDMW). Sorrento, Italy. IEEE, 2021: 173-180.
- [10] SHAFQAT W, BYUN Y C. Incorporating similarity measures to optimize graph convolutional neural networks for product recommendation[J]. Applied Sciences, 2021, 11(4): 1366.
- [11] HUANG C, XU H, XU Y, et al. Knowledge-aware coupled graph neural network for social recommendation[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(5): 4115-4122.
- [12] SCHLICHTKRULL M, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks[M]. The Semantic Web. Cham: Springer International Publishing, 2018: 593-607.
- [13] HAMILTON W L, YING R, LESKOVEC J. Inductive representation learning on large graphs[C]. Conference on Neural Information Processing Systems, 2017, 30: 1024-1034.
- [14] WANG H W, ZHANG F Z, ZHANG M D, et al. Knowledge-aware graph neural networks with label smoothness regularization for recommender systems[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Anchorage, AK, USA. New York: ACM, 2019: 968-977.
- [15] WANG X, JI H Y, SHI C, et al. Heterogeneous graph attention network[C]//WWW '19: The World Wide Web Conference. San Francisco, CA, USA. New York: ACM, 2019: 2022-2032.
- [16] GAO S, XING X, WANG H D, et al. SRUH-GNN: social recommendation of user homophily based on graph neural network[C]//2023 IEEE 12th Data Driven Control and Learning Systems Conference (DDCLS). Xiangtan, China. IEEE, 2023: 1455-1460.
- [17] TAN Q Y, LIU N H, ZHAO X, et al. Learning to hash with graph neural networks for recommender systems[C]//WWW '20: Proceedings of The Web Conference 2020. Taipei, Taiwan. New York: ACM, 2020: 1988-1998.
- [18] WANG Y F, TANG S Y, LEI Y T, et al. DisenHAN: disentangled heterogeneous graph attention network for recommendation[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. Virtual Event, Ire-

land.New York: ACM 2020: 1605–1614.

- [19] WANG X ,HE X N ,WANG M ,et al.Neural graph collaborative filtering [C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval.Paris ,France.New York: ACM 2019: 165–174.
- [20] ZHANG M H ,CHEN Y X.Inductive matrix completion based on graph neural networks [C]//Proceedings of the Eighth International Conference on Learning Representations 2020: 78–92.
- [21] KIM Y.Convolutional neural networks for sentence classification [C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP) .Doha ,Qatar.Association for Computational Linguistics 2014 5: 1746–1751.
- [22] DERR T ,MA Y ,TANG J L.Signed graph convolutional networks [C]//2018 IEEE International Conference on Data Mining (ICDM) .Singapore.IEEE 2018: 929–934.
- [23] DING M ,LIN X ,ZENG B ,et al.Hypergraph neural networks with attention mechanism for session-based recommendation [J].Guangdong-Hong Kong-Macao Greater Bay Area Artificial Intelligence and Big Data Forum 2021 41(2) : 21–26.
- [24] ZHOU H C ,TAN Q Y ,HUANG X ,et al.Temporal augmented graph neural networks for session-based recommendations [C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. Virtual Event ,Canada.New York: ACM 2021: 1798–1802.
- [25] ZHANG X D ,ZHOU Y ,WANG J P ,et al.Personal interest attention graph neural networks for session-based recommendation [J].Entropy (Basel ,Switzerland) 2021 23(11) : 1500.
- [26] MENG W J ,YANG D Q ,XIAO Y H.Incorporating user micro-behaviors and item knowledge into multi-task learning for session-based recommendation [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. Virtual Event ,China.New York: ACM 2020: 1091–1100.
- [27] XIA X ,YIN H Z ,YU J L ,et al.Self-supervised graph co-training for session-based recommendation [C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. Virtual Event ,Queensland ,Australia.New York: ACM 2021: 2180–2190.
- [28] TAO Y ,LI Y ,ZHANG S ,et al.Revisiting graph based social recommendation: a distillation enhanced social graph network [C]//Proceedings of the ACM Web Conference 2022. Virtual Event ,Lyon ,France.New York: ACM 2022: 2830–2838.
- [29] WANG J L ,DING K Z ,ZHU Z W ,et al.Session-based recommendation with hypergraph attention networks [M]//Proceedings of the 2021 SIAM International Conference on Data Mining (SDM) .Philadelphia ,PA: Society for Industrial and Applied Mathematics 2021: 82–90.
- [30] DENG Q L ,WANG K ,ZHAO M H ,et al.Personalized bundle recommendation in online games [C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. Virtual Event ,Ireland.New York: ACM , 2020: 2381–2388.
- [31] CHEN T ,YANG F ,GUO X L.Optimal bundling in a distribution channel in the presence of substitutability and complementarity [J].International Journal of Production Research 2021 59(4) : 1145–1165.
- [32] GUO X L ,ZHENG S M ,YU Y G ,et al.Optimal bundling strategy for a retail platform under agency selling [J].Production and Operations Management 2021 30(7) : 2273–2284.
- [33] VIJAIKUMAR M ,SHEVADE S ,MURTY M N.GRAM-SMOT: top-N personalized bundle recommendation via graph attention mechanism and submodular optimization [M]//Machine Learning and Knowledge Discovery in Databases. Cham: Springer International Publishing 2021: 297–313.
- [34] ZHAO S ,WEI W ,ZOU D ,et al.Multi-view intent disentangle graph networks for bundle recommendation [J].Proceedings of the AAAI Conference on Artificial Intelligence 2022 36(4) : 4379–4387.
- [35] WANG X ,LIU X ,LIU J ,et al.Relational graph neural network with neighbor interactions for bundle recommendation service [C]//2021 IEEE International Conference on Web Services (ICWS) .Chicago ,IL ,USA.IEEE 2021: 167–172.
- [36] ZHENG Z ,WANG C ,XU T ,et al.Drug package recommendation via interaction-aware graph induction [C]//Proceedings of the Web Conference 2021.Ljubljana ,Slovenia.New York: ACM 2021: 1284–1295.
- [37] XIA L H ,HUANG C ,XU Y ,et al.Multiplex behavioral relation learning for recommendation via memory augmented transformer network [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Infor-

- mation Retrieval. Virtual Event ,China. New York: ACM 2020: 2397-2406.
- [38] XIA L H ,HUANG C ,XU Y ,et al. Multi-behavior enhanced recommendation with cross-interaction collaborative relation modeling[C]//2021 IEEE 37th International Conference on Data Engineering (ICDE) .Chania ,Greece.IEEE 2021: 1931-1936.
- [39] YU H F ,E X ,LI X L ,et al. Multi-behavior recommendation based on simplified graph convolutional networks [C]//2021 4th International Conference on Artificial Intelligence and Big Data (ICAIBD) .Chengdu ,China.IEEE 2021: 277-282.
- [40] WEI Y H ,MA H F ,WANG Y K ,et al. Multi-behavior recommendation with two-level graph attentional networks [M]//Data-base Systems for Advanced Applications. Cham: Springer International Publishing 2022: 248-255.
- [41] YU B ,ZHANG R Q ,CHEN W ,et al. Graph neural network based model for multi-behavior session-based recommendation [J]. GeoInformatica 2022 26(2) : 429-447.
- [42] FENG Y F ,HU B B ,LV F Y ,et al. ATBRG: adaptive target-behavior relational graph network for effective recommendation [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. Virtual Event ,China. New York: ACM 2020: 2231-2240.
- [43] GUO Z W ,WANG H. A deep graph neural network-based mechanism for social recommendations [J]. IEEE Transactions on Industrial Informatics 2021 17(4) : 2776-2783.
- [44] YU J L ,YIN H Z ,LI J D ,et al. Self-supervised multi-channel hypergraph convolutional network for social recommendation [C]//Proceedings of the Web Conference 2021. Ljubljana ,Slovenia. New York: ACM 2021: 413-424.
- [45] HUANG C ,XU H C ,XU Y ,et al. Knowledge-aware coupled graph neural network for social recommendation [J]. Proceedings of the AAAI Conference on Artificial Intelligence 2021 35(5) : 4115-4122.
- [46] YU J L ,YIN H Z ,LI J D ,et al. Enhancing social recommendation with adversarial graph convolutional networks [J]. IEEE Transactions on Knowledge and Data Engineering 2022 34(8) : 3727-3739.
- [47] FAN W Q ,MA Y ,LI Q ,et al. Graph neural networks for social recommendation [C]//WWW '19: The World Wide Web Conference. San Francisco ,CA ,USA. New York: ACM 2019: 417-426.
- [48] ZHANG C Y ,WANG Y ,ZHU L ,et al. Multi-graph heterogeneous interaction fusion for social recommendation [J]. ACM Transactions on Information Systems 2022 40(2) : 1-26.

A survey of multi-scenario applications of graph neural network in recommendation system

XING Xing ,LIU Jiawen ,WANG Tianchi ,WANG Hongda ,JIA Zhichun

(College of Information Science and Technology ,Bohai University ,Jinzhou 121013 ,China)

Abstract: The recommendation system can quickly and effectively obtain valuable information from complex data. Traditional recommendation is limited in terms of new users and new projects ,and data scarcity makes it difficult to recommend ,while ignoring the evolution of user interest. In view of the limitations of traditional recommendation methods in the face of complex ,large-scale and dynamic recommendation scenarios ,graph neural network technology has attracted wide attention in academia. Graph neural networks have advantages in dealing with graph data and complex interactions ,and can improve the personalization ,interpretability and timeliness of recommendations. Based on the interaction between graph structure data and nodes ,graph neural network uses the characteristics of nodes and neighbor information to recommend ,which improves the accuracy of recommendation. Firstly ,the basic principle and common models of graph neural network are introduced. Secondly ,the problems faced by the current graph neural network in recommendation are analyzed ,and the countermeasures are discussed. Finally ,according to different recommendation scenarios ,the coping methods in the existing research are classified and summarized.

Key words: recommendation systems; graph neural network; recommendation scenario