

# 生成对抗网络及其在电力系统中的应用综述

邵振国, 张承圣, 陈飞雄, 谢雨寒

(福建省电器智能化工程技术研究中心(福州大学电气工程与自动化学院), 福建省 福州市 350108)

## A Review on Generative Adversarial Networks for Power System Applications

SHAO Zhenguo, ZHANG Chengsheng, CHEN Feixiong, XIE Yuhua

(Fujian Smart Electrical Engineering Technology Research Center (College of Electrical Engineering and Automation, Fuzhou University), Fuzhou 350108, Fujian Province, China)

**ABSTRACT:** With the rapid development of power systems, how to fully utilize the massive, multi-source and multi-dimensional power data is one of the important technical issues faced by the power industry currently. Compared with the traditional machine learning algorithms, deep learning has superior performance in dimensionality reduction, non-linear fitting and feature extraction. Among them, the generative adversarial network (GAN) has advantages in power data enhancement and generation. In this paper, the fundamental theory of GAN is introduced, and the advantages and disadvantages of GAN are analyzed. From the perspective of the network structure and the objective function, four GAN derivative models widely used in power systems are introduced respectively. On this basis, the applications of GAN in power systems are reviewed in detail, and the GAN models in each application scenario and its characteristics are discussed. Finally, the problems to be solved for further application of GAN in power systems are summarized, and deeper and broader applications of GAN are presented.

**KEY WORDS:** deep learning; generative adversarial network; power system; data enhancement; data generation

**摘要:** 随着电力系统的迅猛发展, 如何高效利用海量、多源、多维的电力数据, 是当前电力行业面临的重要技术问题之一。相对于传统机器学习算法, 深度学习具有较强的数据降维能力、非线性拟合能力和特征提取能力。生成对抗网络(generative adversarial network, GAN)作为一类深度学习模型, 能够很好地实现电力数据样本的增强与生成。该文首先介绍 GAN 的基本原理, 分析其优势与劣势; 此后从网络结

构与目标函数的角度出发, 分别介绍在电力系统中应用较为广泛的 4 种 GAN 衍生模型, 进而对 GAN 在电力系统中的应用现状进行详细的综述, 归纳每个应用场景所采用的 GAN 模型及其特点; 最后, 总结 GAN 在电力系统中进一步深入应用所要解决的问题, 并展望未来的应用前景。

**关键词:** 深度学习; 生成对抗网络; 电力系统; 样本增强; 样本生成

## 0 引言

以新能源为主体的新型电力系统的发展将呈现新的态势: 电网规模增大且结构更加复杂; 可再生能源与电力电子设备接入电网的比例逐渐提高; 现代信息技术、计算机技术、通信技术与电力系统的融合程度加深; 监测与采集技术的进步带来数据规模爆发式增长等等<sup>[1]</sup>。面对电网海量、多源、多维的复杂数据, 如何高效利用这些数据, 是新型电力系统发展面临的重要技术问题之一。一直以来, 人工智能作为数据科学的重要组成部分, 通过数据分析和挖掘从海量来源的数据中提取有价值的信息, 揭示复杂系统的内在规律。电力系统是人工智能技术重要应用领域之一, 相关研究已经覆盖发、输、变、配、用、调等电力生产的各个环节<sup>[2-3]</sup>。

机器学习作为人工智能技术的核心, 能够使计算机具有模拟人类学习新事物的能力, 并在积累经验中不断改善自身性能。但传统机器学习算法, 如 BP 神经网络(back propagation neural network, BPNN)、贝叶斯网络(Bayesian network, BN)、支持向量机(support vector machine, SVM)等, 大多为浅层结构, 数据分析能力较弱, 对于实际复杂问题的泛化能力不足, 应用效果主要取决于数据特征本身的表达能力<sup>[4-5]</sup>。在电力系统领域, 风光等可再生能

**基金项目:** 国家自然科学基金项目(51777035, 52107080); 福建省自然科学基金重点项目(2020J02028)。

Project Supported by National Natural Science Foundation of China (51777035, 52107080); Key Project of Natural Science Foundation of Fujian Province (2020J02028).

源的不确定性与智能电网的时变性、非线性和局部可观测性交互影响,使得浅层算法难以充分挖掘电力数据所蕴含的信息与特征<sup>[6-7]</sup>。

近年来,以深度学习(deep learning, DL)<sup>[8]</sup>为代表的新一代人工智能技术迅速发展。与传统机器学习算法相比,深度学习具有如下优势:1)不同于传统机器学习算法的浅层结构,深度学习算法具有足够的网络深度,因此,深度学习具有很强的数据降维和分析能力;2)深度学习具有强非线性拟合能力和特征提取能力,通过直接学习数据样本的概率分布,能从包含若干复杂特性的原始数据样本中提炼出关键信息,不会受限于数据自身的特征表达能力强弱。依据模型对数据的建模方式,可将深度学习模型分为生成模型和判别模型两大类。以卷积神经网络(convolutional neural networks, CNN)<sup>[9]</sup>、循环神经网络(recurrent neural network, RNN)<sup>[10]</sup>、长短期神经网络(long short-term memory, LSTM)<sup>[11]</sup>为代表的判别模型,在电力系统领域内常被用于解决分类问题,即将所给训练样本分成对应的类别,其中 CNN 擅长处理多维电力数据, RNN 及其变体 LSTM 擅长处理与时间相关的电力数据序列。但判别模型在电力系统领域内存在两个应用瓶颈:其一,电力数据在采集与传输过程中存在缺失、重复、异常等质量问题,而数据样本质量不佳将导致判别模型难以完整挖掘电力数据特征,引起判别模型的判别精度下降<sup>[12-14]</sup>;其二,在原始数据样本质量完好的情况下,由于判别模型仅能对数据进行分类判别,而无法根据少量的原始数据,生成大量特征近似于原始数据的样本,因此难以解决如新能源场景生成、电力数据重建等电力数据样本生成方面的问题。

相对于判别模型,生成模型是深度学习中的另一类重要模型,包括赫姆霍兹机(Helmholtz machines)<sup>[15]</sup>、变分自动编码器(variational auto-encoder, VAE)<sup>[16]</sup>、深度信念网络(deep belief network, DBN)<sup>[17]</sup>等。目前,由 Goodfellow 等人提出的生成对抗网络(generative adversarial networks, GAN)<sup>[18]</sup>是生成模型中样本学习能力较强且应用较为广泛的一种算法<sup>[19]</sup>。有别于判别模型, GAN 作为生成模型的一种,当原始电力数据质量不佳时,其可以通过生成类似于原始数据且服从同一概率分布的样本,补全并增强数据样本,提升原始数据样本质量;除此以外,在原始数据样本质量完好的情况下, GAN 可以基于少量的原始数据,生成大

量特征相似的数据样本,解决判别模型无法生成数据样本的瓶颈,有效提升深度学习解决实际复杂问题的泛化能力<sup>[20]</sup>。

GAN 受博弈论中两人零和博弈思想的启发,主要由生成器和判别器两个部分组成。生成器的目的是生成近似于真实的样本去欺骗判别器,而判别器是去区分真实的样本和生成的样本, GAN 通过对抗训练来不断提高生成器和判别器各自的生成能力和判别能力,最终达到一个纳什均衡的状态<sup>[21]</sup>。目前, GAN 已被广泛应用于图像生成<sup>[19]</sup>、计算机视觉<sup>[22-23]</sup>、语音和语言处理<sup>[24-25]</sup>、电脑病毒监测<sup>[26]</sup>、棋类比赛程序<sup>[27]</sup>等问题的研究中。近年来, GAN 在电力系统暂态稳定性分析、电力系统设备故障诊断、电力系统图像增强、电力系统量测数据重建、电力系统负荷预测和用户用电行为分析、以及可再生能源出力场景分析等领域也得到了广泛的应用。

本文从 GAN 算法在电力系统中的应用展开讨论,首先介绍 GAN 的基本原理,分析当前 GAN 模型的优势与劣势。其次综述在电力系统中应用较为广泛的 4 种 GAN 经典衍生模型,而后分析并归纳 GAN 在电力系统中的具体应用。最后分析并总结若干科学问题,展望未来的研究方向。

## 1 生成式对抗网络

### 1.1 GAN 的基本原理

GAN 由一个生成器(generator,  $G$ )和一个判别器(discriminator,  $D$ )构成,  $G$  和  $D$  均由神经网络实现,其基本结构如图 1 所示。

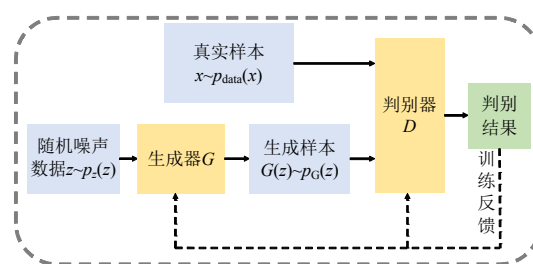


图 1 GAN 基本结构

Fig. 1 Basic structure of GAN

生成器的输入是一组服从概率分布  $p_z(z)$  的随机噪声数据  $z$ , 输出为服从概率分布  $p_G(z)$  的生成数据样本  $G(z)$ 。生成样本  $G(z)$  和服从概率分布  $p_{data}(x)$  的真实样本  $x$  作为判别器  $D$  的输入, 判别器  $D$  的输出为一个标量  $D(G(z))$ , 表示生成样本  $G(z)$  服从真实分布  $p_{data}(x)$  的概率。

生成器的训练目标是使生成样本  $G(z)$  的概率分布  $p_G(z)$  尽可能地与真实样本  $x$  的概率分布  $p_{\text{data}}(x)$  相同。判别器的训练目标是尽可能正确地判别其输入是真实样本还是生成样本,而判别结果将以梯度函数的形式进行反馈,对生成器和判别器的网络结构进行优化。生成器和判别器经过上述的对抗训练后,达到一个纳什平衡状态,即判别器  $D$  判断不出其输入是真实样本还是生成样本,此时就可以认为生成器  $G$  已经学习到真实样本的概率分布,即生成器  $G$  的生成样本  $G(z)$  和真实样本都服从概率分布  $p_{\text{data}}(x)$ 。

根据生成器  $G$  与判别器  $D$  的训练目标,生成器和判别器的损失函数  $L_G$  和  $L_D$  分别如式(1)、(2)所示。

$$L_G = -E_{z \sim p_z(z)} \{\log[1 - D(G(z))]\} \quad (1)$$

$$L_D = -E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{z \sim p_z(z)} \{\log[1 - D(G(z))]\} \quad (2)$$

式中  $E$  表示分布的期望。基于式(1)、(2),可以设计出如式(3)所示的 GAN 的目标函数:

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{z \sim p_z(z)} \{\log[1 - D(G(z))]\} \quad (3)$$

式中  $V(D, G)$  为一个二分类的交叉熵函数,该函数的最终目标是最小化生成样本概率分布  $p_G(z)$  和真实样本概率分布  $p_{\text{data}}(x)$  之间的 JS 距离<sup>[18]</sup>。

## 1.2 GAN 的优势和劣势

与其他常见的生成模型相比较, GAN 有如下优势:

1) 在工作机理方面, GAN 的生成器可以直接对数据进行采样,学到一个近似于真实数据分布的函数;而判别器可以直接拟合采样数据的概率分布,对生成器的函数进行参数优化,这意味着 GAN 具有充分的能力去挖掘数据样本的概率分布,不需要知道真实数据样本的显式分布,同时也不需要更多的数学假设条件。

2) 在网络结构方面, GAN 的生成器和判别器可以采用深度神经网络,如自动编码神经网络和卷积神经网络等,构建深度生成式模型;相较于其他非深度生成式模型,其生成的数据样本质量较高,生成速度较快。

3) 在目标函数方面,生成器的目标函数使得生成数据的概率分布趋于真实数据概率分布,判别器的目标函数则是用于衡量生成数据与真实数据

之间的概率分布差异; GAN 通过自身对抗训练方式,使得模型能够自发性地学习数据样本的内在规律。

尽管 GAN 在某些方面取得了令人满意的效果,但其在理论和实践方面也存在着一一定的劣势,如下所示:

1) 理论方面, GAN 训练过程的稳定性和收敛性难以保证,容易发生模式崩塌现象,导致生成器学到的模式仅仅覆盖真实数据中的部分模式,生成样本的多样性不足。此外,由于标准的 GAN 用 JS 距离来度量真实数据分布和生成数据分布之间的差异,如果生成样本与真实样本之间的概率分布没有重合的部分,则模型可能无法取得最优解,导致 GAN 出现梯度消失或过拟合等问题。

2) 在实际应用中,因为 GAN 在训练中需要交替训练生成器和判别器两个模块,如果没有很好地同步生成器和判别器之间的参数优化过程,会使得 GAN 的训练结果不理想;同时, GAN 的目标函数表示的是 GAN 模型的训练指向, GAN 模型并没有具体的建模表达式,因而训练完成的生成器是一种隐式建模的黑盒模型,可解释性较差,导致研究人员无法量化地判断生成器在什么样的条件下能够生成更高质量的样本。

## 2 GAN 的典型衍生模型对比及特点分析

针对 GAN 存在的不足,学者们分别从网络结构与目标函数等角度出发,提出了大量衍生模型<sup>[28]</sup>。其中,4 个典型的 GAN 衍生模型在电力系统领域应用较为广泛,分别是条件生成对抗网络(conditional generative adversarial network, CGAN)、卷积生成对抗网络(deep convolutional generative adversarial network, DCGAN)、Wasserstein 生成对抗网络(Wasserstein generative adversarial network, WGAN)、引入梯度惩罚的 Wasserstein 生成对抗网络(Wasserstein generative adversarial network with gradient penalty, WGAN-GP),上述 4 种 GAN 衍生模型的特点和适用场景如表 1 所示。

### 2.1 网络结构衍生的典型模型

由于 GAN 训练过程的不稳定,以及部分应用场景对所生成的数据样本具有一定的条件要求,因而有专家学者对 GAN 的网络结构进行拓展衍生。本文将网络结构衍生进一步细分为神经网络结构衍生与模型网络结构衍生两类,其中神经网络结构

表 1 GAN 的典型衍生模型  
Table 1 Typical derivative models of GAN

模型名称	改进方法	优点	缺点	常见的应用场景
CGAN <sup>[29]</sup>	网络结构：添加条件信息 $c$ 形成训练约束	在生成样本与真实样本中添加标签，为训练提供指向性	对数据集要求较高，数据需要有对应的标签信息	适用于有监督学习，或生成目标有指向性的场景
DCGAN <sup>[30]</sup>	网络结构：采用卷积神经网络作为生成器与判别器的网络结构	训练过程更加稳定，收敛性更强，生成样本多样性更丰富	需要根据数据集调整相应的网络初始化参数，易出现梯度消失或爆炸现象	使用率较高，适用于大部分场景
WGAN <sup>[31]</sup>	目标函数：引入 Wasserstein 距离取代 JS 距离	训练过程更加稳定，理论上解决了梯度消失的问题	所采用的权重裁剪，可能会导致训练出现梯度消失或爆炸	可适用于原始 GAN 出现梯度消失现象的场景
WGAN-GP <sup>[32]</sup>	目标函数：采用梯度惩罚取代 WGAN 中的权重裁剪	训练过程更稳定，不需要平衡生成器与判别器的优化过程	收敛速度慢，生成样本多样性不如 DCGAN	适用于对训练速度、生成样本多样性要求不高的场景

衍生通过改进生成器与判别器内部的神经网络结构，提升 GAN 的模型性能，解决 GAN 训练过程不稳定等问题。而模型网络结构衍生则是从模型整体的角度出发，针对不同应用场景的具体需求，通过改进模型网络的整体结构，提升 GAN 模型的适用性。模型网络结构衍生以 CGAN 等模型为代表，而神经网络结构衍生以 DCGAN 等模型为代表。

2.1.1 CGAN

GAN 能够学习无标签数据的概率分布，并生成相似概率分布的样本。但当数据集带有标签或者应用场景需要指定生成目标时，因为没有相关约束条件的限制，原始 GAN 模型所生成的结果往往不符合场景要求。针对上述问题，文献[29]基于原始 GAN 模型，提出 CGAN 模型。CGAN 融合了监督学习与无监督学习技术，保留 GAN 中生成器与判别器的博弈结构。CGAN 在 GAN 的基础上添加了条件信息  $c$ ，并将该条件信息同时作为生成器与判别器输入的一部分，CGAN 模型的基本结构如图 2 所示。

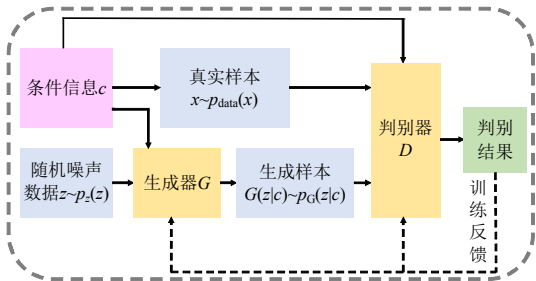


图 2 CGAN 基本结构  
Fig. 2 Basic structure of CGAN

随着网络结构的变化，CGAN 的目标函数也随之出现变化，如式(4)所示：

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [\log D(x|c)] + E_{z \sim p_z(z)} \{\log [1 - D(G(z|c)|c)]\}$$

(4)

根据具体的应用场景， $c$  可以作为数据样本的类别标签，也可以作为一种指向性信息，为生成样本的概率分布提供训练指向。例如在进行电力系统负荷预测时，条件信息可以是负荷影响因素；进行可再生能源场景生成时，条件信息可以是可再生能源出力的时空信息，如日期、地点坐标等；而进行电力设备故障诊断时，条件信息可以是具体的故障类别。

2.1.2 DCGAN

原始 GAN 模型的训练不够稳定，主要原因在于生成器和判别器的神经网络结构较为简单，难以学习到深层的数据特征，导致模型出现模式崩塌现象，使得生成样本多样性不足。为此，文献[30]提出了 DCGAN 模型，该模型将卷积神经网络 CNN 作为 GAN 中生成器与判别器的基本网络结构，增强模型提取样本特征的能力，使得生成样本的概率分布更加接近于真实样本的概率分布，从而保证生成样本的质量。其基本结构如图 3 所示。

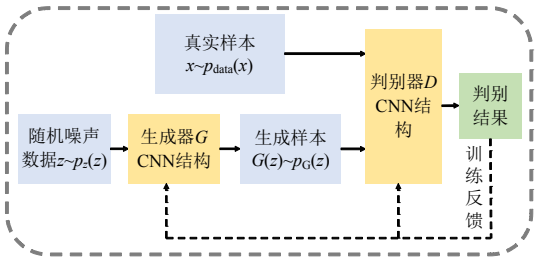


图 3 DCGAN 基本结构  
Fig. 3 Basic structure of DCGAN

在生成器中，DCGAN 直接采用卷积层代替原始 CNN 的池化结构<sup>[33]</sup>，同时输出层采用 ReLU 激活函数<sup>[34]</sup>。在判别器中，DCGAN 采用步幅卷积取代池化结构，输出层采用 leakyReLU 激活函数<sup>[35]</sup>。通过上述改动，DCGAN 可以准确分析输入数据采样点与局部输入信息之间的相关性，挖掘输入数据



的局部信息特征。除此以外, DCGAN 还引入批规范化(BN)层<sup>[36]</sup>, 将梯度传播到神经网络的每一层, 解决初始化差、梯度消失等问题。DCGAN 在电力系统中应用广泛, 是许多其他 GAN 衍生模型的基础。

## 2.2 目标函数衍生的典型模型

原始 GAN 的目标函数容易出现梯度消失现象, 导致模型训练崩溃。因此, 后续许多研究学者针对 GAN 的目标函数进行拓展衍生, 其中比较有代表性的模型有 WGAN 与 WGAN-GP 等。

### 2.2.1 WGAN

原始 GAN 采用 JS 距离来描述式(3)的目标函数, 但当模型刚开始训练时, 生成样本的概率分布和真实样本的概率分布可能完全没有交集。此时 JS 距离恒为常数  $\log 2$ , 目标函数无法准确衡量样本分布之间的距离, 因此出现梯度消失等问题, 导致模型无法继续训练<sup>[18]</sup>。

为此, 文献[31]提出 Wasserstein GAN 模型, 引入 Wasserstein 距离来度量生成样本与真实样本概率分布之间的差异。Wasserstein 距离的定义如下:

$$W(p_{\text{data}}, p_G) = \inf_{\gamma \sim \Omega(p_{\text{data}}, p_G)} E_{(u,v) \sim \gamma} [\|u - v\|] \quad (5)$$

式中:  $\Omega(p_{\text{data}}, p_G)$  是  $p_{\text{data}}$  和  $p_G$  组合起来的所有可能的联合分布的集合; 对于每一个联合分布  $\gamma$ , 可以从联合分布中采样, 得到一个真实样本  $u$  和一个生成样本  $v$ , 并且获得这两个样本间的距离  $\|u - v\|$ , 然后计算在联合分布  $\gamma$  下的期望值  $E_{(u,v) \sim \gamma} [\|u - v\|]$ , 最后在所有可能的联合分布中求出期望值的下界, 该下界即为 Wasserstein 距离。

WGAN 模型基本结构如图 4 所示。

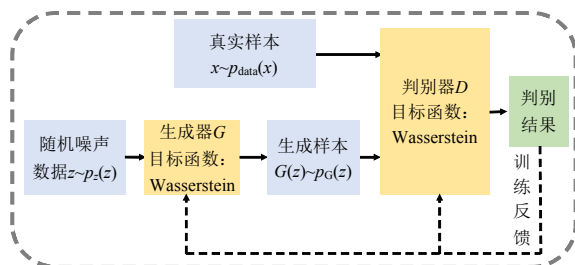


图 4 WGAN 基本结构

Fig. 4 Basic structure of WGAN

WGAN 的目标函数如式(6)所示。

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [D(x)] - E_{z \sim p_z(z)} [D(G(z))] \quad (6)$$

WGAN 很好地解决梯度消失的问题, 在生成样本与真实样本的概率分布不相交或者交集很小的

情况下, Wasserstein 距离依然能够度量两个分布之间的差异, 而不是一个常量; 不同于原始 GAN, Wasserstein 距离可以表示模型训练收敛的程度, 数值越小, 代表 WGAN 训练得越好, 解决了原始 GAN 难以判断模型训练收敛情况的问题。

### 2.2.2 WGAN-GP

Wasserstein 距离通常采用其 Kantorovich-Rubinstein 对偶形式来描述生成样本与真实样本之间的距离:

$$W(p_{\text{data}}, p_G) = \frac{1}{K} \sup_{\|f_D\|_L \leq K} E_{x \sim p_{\text{data}}} [D(x)] - E_{x \sim p_G} [D(x)] \quad (7)$$

式中  $\|f_D\|_L \leq K$  表明判别器函数  $D(x)$  需要满足 K-Lipschitz 连续。WGAN 采用权重裁剪的方法, 限制判别器的网络权重参数, 从而使其满足 Lipschitz 连续。但粗暴的权重裁剪会导致如下问题: 判别器希望尽可能地拉大真假样本分布之间的差距, 然后权重裁剪的策略又独立地限制每一个网络参数的取值范围, 这使得所有的网络参数都将走向极端, 要么取最大值要么取最小值, 导致参数值的分布很不均匀。

为此, 文献[32]在 WGAN 的基础上进行改进, 提出了如图 5 所示的 WGAN-GP 模型。

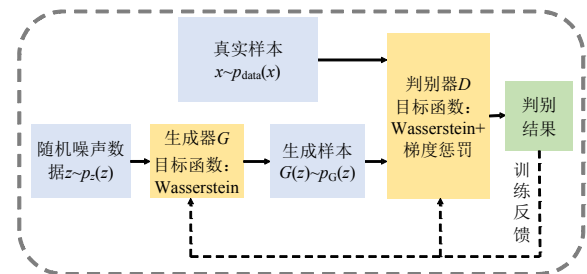


图 5 WGAN-GP 基本结构

Fig. 5 Basic structure of WGAN-GP

该模型使用梯度惩罚项代替 WGAN 中的权重裁剪技巧, 通过限制判别器的梯度不超过 Lipschitz 常数 K 来构造梯度惩罚项, 使判别器函数  $D(x)$  近似满足 K-Lipschitz 连续。此时, WGAN-GP 的目标函数转化为

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [D(x)] - E_{z \sim p_z(z)} [D(G(z))] - \lambda E[\|\nabla D(x')\| - K]^2 \quad (8)$$

式中:  $x' = \varepsilon x + (1 - \varepsilon)G(z)$ ;  $\varepsilon$  表示随机数; 梯度惩罚项的权重系数一般取  $\lambda = 10$ 。

相较于其他 GAN 衍生模型, WGAN-GP 在电力系统领域的应用更为广泛, 生成的样本质量更高, 但它的收敛速度较慢, 往往需要更多的训练次

数才能收敛。

### 3 GAN 在电力系统领域的应用现状

本文依据当前 GAN 在电力系统领域的应用现状,建立生成对抗网络在电力系统中的应用框架。如图 6 所示,依据应用需求,将应用现状分为电力系统数据样本增强与电力系统数据样本生成两

大类,每一大类依据具体应用场景进一步细分。其中,电力系统数据样本增强的应用场景有电力系统暂态稳定性分析、电力系统设备故障诊断、电力系统图像增强,而电力系统数据样本生成的应用场景有电力系统量测数据重建、电力系统负荷预测和用户用电行为分析、可再生能源出力场景分析。

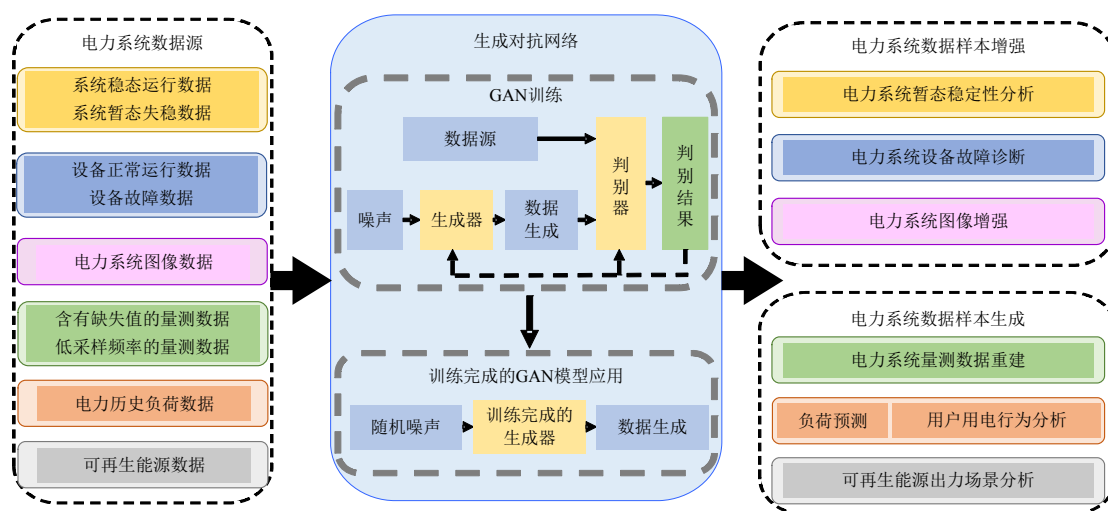


图 6 生成对抗网络在电力系统中的应用框架

Fig. 6 Overview of GAN for power systems applications

#### 3.1 电力系统数据样本增强

当前已有大量数据驱动技术应用于电力系统领域,但由于原始电力数据存在缺失、重复、异常等质量问题,以及部分应用存在数据样本类别不平衡的问题,导致应用效果不佳。针对质量不佳的数据及样本不平衡问题,GAN 能够补全并增强数据样本,提升原始数据样本质量,有效解决数据量匮乏产生的样本不平衡问题。本文对 GAN 在电力系统数据样本增强方面的应用,主要从电力系统暂态稳定性分析、电力系统设备故障诊断、电力系统图像增强等 3 个方面展开综述。

##### 3.1.1 电力系统暂态稳定性分析

电力系统暂态稳定性分析本质上属于二分类问题,一般采用基于相量测量单元 (phasor measurement unit, PMU) 的广域测量系统 (wide area measurement system, WAMS) 数据作为样本对象。如图 7 所示,GAN 的生成器可以在数据样本形成阶段,对失稳数据进行修复、补全,增强数据样本,以进一步实现预防控制策略快速求解与失稳判别评估等。

文献[37]在 CGAN 的基础上提出了双生成器生成对抗网络(double generator LSTM-generative

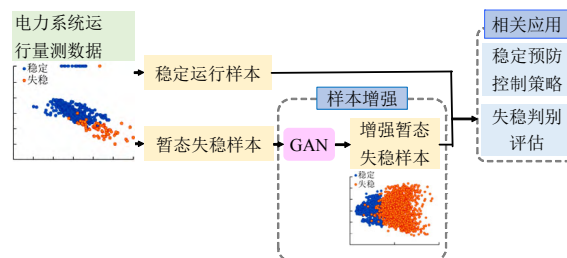


图 7 GAN 暂态稳定性分析流程

Fig. 7 Flowchart of GAN based transient stability analysis method

adversarial network, DGL-GAN), 其中一个生成器用于增强带标签样本的多样性,另一个生成器用于去除噪声、补全缺失数据;判别器用于评估电力系统的暂态稳定性。针对暂态稳定评估的样本不平衡问题,文献[38]提出应用改进 CGAN 模型生成失稳样本,并结合 ELM 筛选出准确度最高的样本,对原始失稳样本进行增强,实现在线暂态稳定评估。文献[39]将 WGAN-GP 模型与迁移学习算法相结合,学习电力系统暂态稳定临界样本的特征参量,进而生成高质量的稳定临界样本。

对于电力系统暂态稳定性分析,GAN 相关模型可以实现数据特征提取和样本增强,解决稳定性评估中较为棘手的数据样本不平衡问题,一定程度

上提升了暂态稳定性评估的准确性和高效性。文献[40]还提出基于 WGAN 模型,学习失稳运行空间与稳定运行空间的映射关系,建立电力系统暂态稳定预防控制模型,实现电力系统暂态稳定预防控制策略的快速求解。至于如何应用 GAN 模型解决不同网络拓扑、不同运行方式下的电力系统暂态稳定性分析问题,有待进一步研究。

### 3.1.2 电力系统设备故障诊断

电力系统设备故障诊断是电力系统自愈过程中的重要环节,对于保障优质电力的正常供应具有重要意义。

在变压器的故障诊断方面,文献[41]针对变压器绝缘劣化后产生的局部放电问题,在边界平衡生成对抗网络 (boundary equilibrium generative adversarial network, BEGAN)的基础上,提出辅助分类-边界平衡生成对抗网络,该网络模型提高了变压器多源放电的诊断精度,解决传统诊断方法的准确性受样本类别非均衡制约的问题。文献[42]结合 CGAN 与 WGAN-GP,提出一种变压器故障数据增强方法,实现故障样本库的类别均衡化目标,提升故障诊断模型的整体分类性能。文献[43]将强化学习中的策略梯度算法引入循环卷积生成式对抗网络 (recurrent convolutional generative adversarial networks, RCGAN)中,实现电力变压器油色谱故障样本的扩充,提高变压器故障分类准确率。

在风力发电设备故障诊断方面,文献[44]围绕风机主轴承故障识别问题,提出辅助分类生成对抗网络 (auxiliary classifier generative adversarial networks, AC-GAN)模型,生成大量非平衡场景下的小样本故障类型数据,提高故障识别准确率。文献[45]提出将 AC-GAN 模型与 WGAN-GP 模型相结合,扩充风电机组主轴承的故障样本,提升风电机组主轴承故障诊断的正确率。文献[46]应用 GAN 模型对风电机组的在线状态数据进行分析,判别故障风机所在位置。

此外,在配电网与智能开关设备的故障诊断方面,文献[47]针对配电网停电故障诊断问题,采用 GAN 模型以无监督训练的方式,提取配电网正常运行条件下的时空监测数据特征,进而结合宽度优先搜索算法 (breadth first search, BFS),实现配电网中的停电故障诊断。文献[48]针对智能开关设备故障诊断问题,结合多重生成对抗网络 (triple generative adversarial network, TGAN)与 DS 证据理

论,获取表征开关设备状态的特征信息和状态类别,实现对开关设备运行状态的判别和诊断。

如图 8 所示,针对电力系统设备故障诊断中,故障样本过少、故障类别样本不平衡等问题, GAN 模型可以充分利用电力系统的在线监测、离线运维数据,直接挖掘设备故障特征,增强故障数据样本,有助于进一步提升故障诊断的准确性。但当前的研究主要围绕易分类和易识别的电力设备故障,如何实现电力设备复杂故障的诊断还有待于研究。




图 8 GAN 设备故障诊断流程

Fig. 8 Flowchart of GAN based equipment fault diagnosis method

### 3.1.3 电力系统图像增强

传统图像处理方法往往通过人为制定规则,对图像特征进行数学运算。但图像通常包含较为复杂的背景噪声,基于规则的算法易受噪声干扰,且难以有效地挖掘图像中丰富的特征。GAN 的出现为电力系统图像分析提供新的思想和工具,研究人员将图像的像素点等信息视为数据样本,通过 GAN 处理电力图像的像素信息,进而实现电力系统图像增强。

文献[49]提出在 WGAN 模型中引入残差网络,对绝缘子图像去模糊化,还原图像的细节,实现绝缘子图像的高清化。文献[50]构建 GAN 以生成图像场景和人体轮廓,同时基于 GAN 优化图像细节,实现对变电站工作人员的异常行为预测。文献[51]采用专注递归生成对抗网络 (attentive recurrent generative adversarial network, ARGAN)去除风电机组叶片图像的阴影区域,提高风电机组叶片的故障图像识别度。

针对图像样本量较小的问题,文献[43]将 GAN 用于扩充电力变压器的油色谱故障样本,文献[52]基于 CGAN 模型对异物入侵的输电线路图像样本进行扩充。此外,也有学者通过将电网数据样本转换成图像样本,再进一步应用 GAN 对转换后的图像进行处理。

GAN 作为在计算机视觉以及图像领域应用较为广泛的模型,泛化能力较强,能够很好地适用于电力巡检、变电站异常行为预测、风电机组故障识别、变压器故障识别等方面。但目前 GAN 及其衍生

模型，只能采用去模糊化、优化细节等方式解决简单的电力图像质量问题，可作为辅助工具实现电力系统图像样本的增强，而不能取代专业的工作人员。

表 2 从应用场景、所用 GAN 模型和方法特点几个方面对 GAN 在电力系统数据样本增强方面的应用进行了总结与对比。

表 2 GAN 在电力系统数据样本增强方面的应用  
Table 2 Applications of GAN in power system data enhancement

应用场景	文献	文献来源及发表时间	GAN 模型	方法特点
电力系统 暂态稳 定性分析	[37]	电网技术, 2021	DGL-GAN	模型含有两个生成器，分别用于样本增强与数据去噪
	[38]	电力系统自动化, 2019	CGAN	增强失稳样本后，结合 ELM 筛选准确度最高的样本
	[39]	电网技术, 2021	WGAN-GP	与迁移学习结合，增强稳定临界样本
	[40]	电力系统自动化, 2020	WGAN	增强失稳样本，并学习失稳与稳定样本之间的映射关系
电力设备 故障诊断	[41]	中国电机工程学报, 2021	AC-BEGAN	增强变压器局部放电数据样本，提升放电识别诊断效果
	[42]	电网技术, 2020	CGAN	增强变压器故障数据样本，实现故障样本库类别均衡化
	[43]	电力自动化设备, 2020	RCGAN	结合策略梯度算法，增强变压器油色谱故障样本
	[44]	中国电机工程学报, 2020	AC-GAN	增强风机主轴承非平衡场景下小样本故障类型数据样本
	[45]	电力系统自动化, 2021	AC-GAN	增强风电机组主轴承的故障样本
	[46]	仪器仪表学报, 2020	GAN	增强风电机组的健康状态 SCADA 数据样本
	[47]	IEEE Transactions on Smart Grid, 2020	GAN	增强配电网停电故障样本，结合 BFS 算法实现停电诊断
	[48]	电力系统保护与控制, 2021	TGAN	增强表征开关设备状态的特征信息与状态类别样本
电力系统 图像增强	[49]	电力自动化设备, 2020	WGAN	增强绝缘子图像样本，实现图像高清化
	[50]	南方电网技术, 2019	GAN	增强变电站图像场景和工作人员人体轮廓图像样本
	[51]	华北电力大学学报, 2021	ARGAN	增强风电机组叶片图像样本，去除阴影区域
	[52]	电力系统保护与控制, 2021	CGAN	增强有异物入侵的输电线路图像样本

3.2 电力系统数据样本生成

电力系统存在许多与数据样本生成相关的工程问题，GAN 作为一种典型的生成模型，可以有效生成电力系统数据样本。本文将 GAN 在电力系统数据样本生成方面的具体应用细分为电力系统量测数据重建、电力系统负荷预测和用户用电行为分析、可再生能源出力场景分析等 3 个部分。

3.2.1 电力系统量测数据重建

电力量测数据对电力系统的状态估计、设备评估、系统运行优化具有重要意义，但量测数据的采集、传输、转换各个环节都有可能发生故障或受到干扰，导致数据出现缺失。

在缺失数据重建方面，文献[53]采用 WGAN 对电力系统量测缺失数据进行重建，即使在量测数据出现大量缺失的情况下依然有较高的重建精度，该方法适用于时序相关性较强的电力数据。文献[54]提出应用 GAN 重建缺失的电力暂态量测数据，同时结合极限学习机(extreme learning machine, ELM)实现电力系统的动态安全评估。文献[55]针对窃电检测的量测数据不平衡问题展开研究，通过 WGAN 对原始窃电样本进行过采样，从而重建窃电数据样本，实现原始窃电样本的增强。文献[56]将 DCGAN 与双重语义感知重构约束相结合，实现配电网缺失

数据的重建。文献[57]针对目标新能源电站量测数据缺失的问题，将 CGAN 和 DCGAN 模型相结合，学习邻近场站与目标场站之间的数据映射关系，迁移邻近场站数据，实现新能源场站场景缺失数据重建。

当数据的采样频率较低时，数据样本所包含的信息量相对较少，导致数据驱动方法的应用效果不佳，如电力负荷预测精度不高、电力设备故障诊断不准确等等。GAN 也常被应用于重建高采样频率电力数据。文献[58]采用超分辨率生成对抗网络(super-resolution generative adversarial network, SRGAN)，将采样频率为 15 分钟/次的电力系统量测数据重建为 1HZ 的高频数据，提升数据细粒度。文献[59]改进原始 SRGAN 模型，结合数据图像算法提出数据图像超分辨率生成对抗网络(data-image super-resolution generative adversarial network, DISRGAN)模型，用于重建光伏出力数据。文献[60]提出改进的条件超分辨率生成对抗网络(conditional super-resolution generative adversarial network, CSRGAN)模型，同时重建高频量测发电数据与负荷数据。

对于电力系统的重建，GAN 模型能通过无监督训练的方式，自动学习数据之间的关联性与



规律,同时还能生成无限多个符合该关联性与规律的新样本。相较于显式建模模型,GAN 通过隐式建模表达数据的复杂时空关系,具有稳定、准确的重建效果。但当训练数据和待重建数据的特征差异较大时,也有可能导致重建效果劣化。

### 3.2.2 电力系统负荷预测和用户用电行为分析

负荷预测是电力系统规划设计与调度控制的基础,传统的统计学方法主要针对负荷的线性关系进行建模,忽略气候、日期类型等因素对负荷预测的影响,预测准确率较低。而以支持向量机、前馈神经网络等人工智能方法为主的负荷预测模型,虽能达到较为理想的预测精度,但在负荷数据量较大、负荷数据特征较复杂时,往往会伴随陷入局部最优解、梯度消失等问题。相对地,GAN 能够捕捉复杂的非线性序列数据间隐含的深层关系,可有效提高预测精度,在负荷预测领域具有显著的优越性。

文献[61]将 GAN 与 RCGAN 相结合,用 GAN 模型生成数量充足且兼顾负荷时空分布规律的数据,而后基于生成的数据,运用 RCGAN 模型实现空间负荷预测。文献[62]基于 CGAN 模型开展短期负荷预测研究,以负荷影响因素作为条件信息,真实负荷数据作为真实样本,应用 CGAN 实现短期负荷预测。文献[63]改进 GAN 的判别器结构,将半监督学习模式与 GAN 相结合,应用半监督生成对抗网络 (semi-supervised generative adversarial network, SSGAN)实现风电功率预测。

除了负荷预测之外,GAN 模型也被应用于用户用电行为分析中。文献[64]将 DCGAN 与核密度估计(kernel density estimation, KDE)相结合,生成带有标签的用户习惯与负荷模式数据,克服智能电表数据无法提供用户标签的不足。文献[65]提出一种基于 GAN 的负荷图像生成方法,将用户的负荷数据转换为负荷图像,进而通过 GAN 模型生成用户用电行为模式。文献[66]将 CGAN 与联邦学习相结合,实现非侵入式负荷分解。

对于电力系统的负荷预测,GAN 及其衍生模型能够对负荷数据中难以显式建模的复杂时空关系进行无监督训练学习,并生成符合历史负荷变化规律的新样本,实现负荷预测;对于用户用电行为分析,GAN 能够增强用户负荷样本,生成用户用电行为模式。与浅层学习相比,GAN 通过生成对抗的方式,强化对电力负荷数据的特征提取能力,进而使得 GAN 模型所预测的负荷精度更高,对于

用户用电行为的分析更加精确。

### 3.2.3 可再生能源出力场景分析

电力系统中的可再生能源出力具有很强的不确定性,大规模可再生能源并网将对电力系统的优化控制提出诸多挑战。场景分析是一种通过构建确定性场景来分析电力系统不确定性问题的方式,它可以根据不确定性变量的概率特征生成多个确定性场景以描述新能源发电的不确定性。

在可再生能源场景生成方面,文献[67]基于 CGAN 模型,以风/光伏电站的空间位置作为条件信息,学习可再生能源出力的时间-空间相关性,生成风/光场景。文献[68]在 WGAN-GP 的基础上,添加日前预测风电数据作为条件信息,实现可再生能源日前场景的生成。文献[69]改进 WGAN-GP 模型,添加风电站的时空信息作为条件信息,从而生成同一时间段多个风电场的典型场景。文献[70]改进了 DCGAN 模型,引入缩放点注意力机制,将深度卷积网络替换成时序卷积网络,构建时序生成对抗网络 (sequential generative adversarial network, SGAN),生成月度风光发电功率场景。文献[71]建立 VAE 与 CGAN 的联合结构,通过 VAE 提取天气信息的特征,并将相关特征作为 CGAN 的条件信息,生成特定天气条件下的光伏出力场景。

基于所生成的可再生能源出力场景,可以进行可再生能源的容量优化配置。文献[72]采用 GAN 模型生成大量风光出力场景,通过聚类削减得到若干典型场景后,用以构建微电网中分布式电源的容量优化配置模型。文献[73]在 DCGAN 模型的基础上,加入月份标签作为条件信息,生成面向规划的风光联合出力场景,以刻画分布式电源出力的不确定性范围,建立配电网间歇式分布式电源优化配置模型。文献[74]基于 WGAN 模型模拟大量风光资源场景,并综合考虑多能源电力系统的运行特性,构建以经济性最优为目标的新能源电源容量配置模型。文献[75]通过联邦学习建立全局模型,采用最小二乘生成对抗网络 (least square generative adversarial network, LSGAN)构建场景生成模型,有效提升场景生成模型的鲁棒性。

上述研究主要围绕可再生能源出力场景的生成展开,而文献[76]基于 WGAN 模型,不仅对风电和光伏出力的时间序列进行建模,同时还计算出目标电力系统的虚拟净负荷,构建了以可再生能源消纳最大化为目标的优化调度模型。

如图 9 所示,传统方法主要通过随机抽样概率分布特征、对统计特征进行数学建模、结合预测误差抽样概率分布特征等方式,抽样生成可再生能源出力场景。相较于传统算法,GAN 通过隐式建模的方式挖掘历史数据的高维非线性特征,学习可再生能源出力所包含的时间-空间相关性与气象相关性,提升可再生能源出力不确定性刻画的准确度,能够为电力系统的优化控制提供翔实、可靠的依据。

表 3 从应用场景、所用 GAN 模型和方法特点几个方面对 GAN 在电力系统数据样本生成方面的应用进行总结与对比。

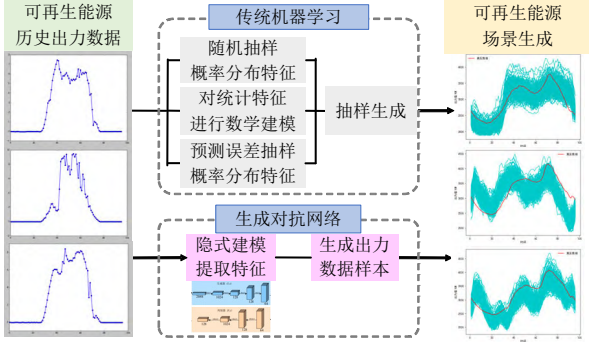


图 9 可再生能源场景分析中 GAN 与传统方法的比较  
Fig. 9 GAN and traditional methods in scenario analysis of renewable energy

表 3 GAN 在电力系统数据样本生成方面的应用  
Table 3 Applications of GAN in power system data generation

应用场景	文献	文献来源及发表时间	GAN 模型	方法特点
电力系统量测数据重建	[53]	中国电机工程学报, 2019	WGAN	重建电力系统电压、电流、有功、无功等量测数据
	[54]	IEEE Transactions on Power Systems, 2019	GAN	重建电力系统暂态量测数据, 结合 ELM 评估动态安全
	[55]	电网技术, 2020	WGAN	过采样重建原始窃电样本
	[56]	电力系统自动化, 2020	DCGAN	重建配电网缺失数据
	[57]	电网技术, 2021	CGAN	重建新能源电站场景量测数据
	[58]	IEEE Access, 2020	SRGAN	超分辨率重建, 生成高采样频率电力系统量测数据
	[59]	International Journal of Electrical Power & Energy Systems, 2021	DISRGAN	超分辨率重建, 生成高采样频率光伏出力数据
	[60]	Applied Energy, 2021	CSRGAN	超分辨率重建, 生成高采样频率发电数据与负荷数据
	[61]	中国电机工程学报, 2020	GAN 和 RCGAN	生成预测数据, 实现空间负荷预测
电力系统负荷预测和用户用电行为分析	[62]	电力系统自动化, 2021	CGAN	生成预测数据, 实现短期负荷预测
	[63]	International Journal of Electrical Power & Energy Systems, 2021	SSGAN	生成预测数据, 实现风电功率预测
	[64]	IEEE Transactions on Smart Grid, 2020	DCGAN	结合 KDE 生成用户习惯与负荷模式数据
	[65]	IEEE Transactions on Smart Grid, 2021	GAN	生成用户用电行为模式数据
	[66]	电测与仪表, 2020	CGAN	结合联邦学习, 生成非侵入式负荷数据
	[67]	IEEE Transactions on Power System, 2018	CGAN	生成风/光场景
可再生能源出力场景分析	[68]	中国电机工程学报, 2020	WGAN-GP	生成可再生能源日前场景
	[69]	International Journal of Electrical Power & Energy Systems, 2020	WGAN-GP	生成风电场多个时间段的典型场景
	[70]	中国电机工程学报, 2021	SGAN	生成月度风光出力场景
	[71]	电网技术, 2021	CGAN	结合 VAE, 生成特定天气条件下的光伏出力场景
	[72]	电网技术, 2019	GAN	生成风光出力场景, 实现分布式电源优化配置
	[73]	电网技术, 2021	CGAN	生成面向规划的风光联合出力场景
	[74]	电力自动化设备, 2020	WGAN	生成风光出力场景, 实现新能源电源容量配置
	[75]	IEEE Transactions on Industrial Informatics, 2021	LSGAN	结合联邦学习, 生成可再生能源场景
	[76]	中国电机工程学报, 2021	WGAN	生成风光出力场景, 实现虚拟净负荷的计算

3.3 GAN 在电力系统中的应用总结

从 GAN 在电力系统样本增强和生成方面所解决的问题本质、优势及不足等角度出发, 对 GAN

的应用现状进行总结, 如表 4 所示。

样本增强方面, GAN 所解决的问题本质为样本不平衡与电力图像质量提升。其中, 在电力系统

表 4 GAN 在样本增强和生成方面的应用总结

Table 4 Qualitative comparison of GAN in data enhancement and generation

应用领域	解决的问题	优势	不足
样本增强	稳定分析 样本不平衡(失稳样本较少)	样本增强的准确性高，模型抗噪声干扰的能力强，计算效率高	缺乏考虑电网拓扑结构与运行方式变化对样本增强的影响
	故障诊断 样本不平衡(故障样本较少)	样本增强的效率高、质量好，模型的稳定性强	无法应用于难以分类和识别的故障
	图像增强 电力图像质量提升	图像去模糊化效果好，细节优化能力强	图像增强的方式简单，无法解决更为复杂的电力图像质量问题
样本重建	缺失数据重建/超分辨率重建	数据重建的稳定性好，准确性高	待重建数据较少时，难以提取特征，影响重建效果
本 负荷预测/	用户负荷数据生成	负荷预测精度高，用户负荷	需要足量的历史负荷数据作为训练集
生 行为分析		数据生成效率高、准确性好	
成 场景生成	场景数据生成	数据生成准确性高，刻画新能源不确定性更加精准	需要足量的新能源历史出力场景数据作为训练集

暂态稳定性分析与电力系统设备故障诊断领域，所面临的样本不平衡问题，GAN 主要应用于增强数量极少的失稳样本及故障样本；电力图像增强领域，GAN 主要应用于提升图像的质量。每个细分领域的优势与不足如表 4 所示。

样本生成方面，每一个细分领域内，GAN 所解决的问题本质均不同。数据重建方面，GAN 所解决的问题本质分为缺失数据重建与超分辨率重建，前者用于重建存在缺失现象的量测数据，以实现数据片段的补缺，后者则是用于重建高采样频率/分辨率的量测数据，实现高量测精度数据的生成。负荷预测与用户用电行为分析方面，GAN 主要应用于负荷预测数据的生成，并基于所生成的用户负荷数据分析用户用电行为。可再生能源场景生成方

面，GAN 应用于可再生能源场景数据的生成。每个细分领域的优势与不足同样如表 4 所示。

针对 GAN 在电力系统领域所解决的问题本质及相关应用，进一步从 GAN 衍生模型的角度出发，对 GAN 在电力系统中的应用现状进行总结。如表 5 所示，衍生类型可分为神经网络结构衍生、目标函数衍生、模型网络结构衍生 3 大类。其中神经网络结构衍生与目标函数衍生的目的及优势是解决原始 GAN 模型存在的问题，模型网络结构衍生的目的是依据电力系统应用需求，进一步拓展原始 GAN 模型的功能。因而大部分模型网络结构衍生的 GAN 模型也都包含神经网络结构衍生与目标函数衍生。每种 GAN 衍生类型的模型名称、衍生途径、优势、不足、应用领域及应用现状如表 5 所示。

表 5 GAN 衍生模型的应用总结

Table 5 Summary of derivative GAN models used in power system

衍生类型	主要衍生模型	衍生途径	优势	不足	应用领域	应用现状
神经网络结构衍生	DCGAN/BEGAN/RCGAN	改进生成器与判别器的内部神经网络结构	解决原始 GAN 训练过程不稳定，数据特征提取能力一般的问题	易出现梯度消失或爆炸现象	所有领域均有涉及	常与其他 GAN 衍生模型结合，提升数据增强与生成质量
目标函数衍生	WGAN/WGAN-GP/LSGAN	改进模型的目标函数	解决原始 GAN 容易出现梯度消失现象，导致模型训练崩溃的问题	收敛速度慢，生成样本多样性不足	所有领域均有涉及	常与其他 GAN 衍生模型结合，提升模型训练稳定性
模型网络结构衍生	CGAN/ACGAN/SGAN	添加条件信息作为类别标签	可以学习多种类别的原始数据样本特征，增强或生成多类别的数据样本	要求原始数据集带有标签信息	所有领域均有涉及	主要应用于样本不平衡问题，或用于生成多类别样本
	DGL-GAN/TGAN/SSGAN	引入机器学习改进模型结构	有助于提升数据增强质量与负荷预测精度	仅适用于特定场景，不具有广泛适用性	样本增强/负荷预测	目前仅应用于暂态稳定评估、开关设备诊断、负荷预测
	SRGAN/DISRGAN/CSRGAN	样本生成模式从基于噪声生成数据，衍生为基于低采样频率数据生成高采样频率数据	针对特定的超分辨率数据重建应用场景，具有良好的重建效果	要求原始数据集同时含有高/低采样频率数据	电力系统量测数据重建	目前仅应用于电力系统量测数据超分辨率重建
	ARGAN	模型网络结构衍生	适用于电力图像去阴影应用场景	适用场景单一	电力系统图像增强	目前仅应用于电力图像去阴影

## 4 结论与展望

本文首先介绍数据驱动技术应用于电力系统的发展趋势及瓶颈,分析 GAN 解决瓶颈的方法途径,阐述了其基本原理及优劣势,介绍典型的 GAN 衍生模型;此后,从电力系统数据样本增强与生成两类应用需求角度,综述每个场景所应用到的 GAN 模型;最后,分析归纳 GAN 模型在每个场景中的应用特点,对 GAN 在样本增强和生成方面的应用做出总结,并从 GAN 衍生模型的角度出发,概述 GAN 的应用现状。

GAN 作为一种生成模型,其本质与核心在于能够学习原始数据样本的概率分布特征,在此基础上,生成类似于原始数据且服从同一概率分布的样本。目前 GAN 在电力系统领域应用较为广泛,能够为电力数据增强与样本生成等提供良好的解决方案,突破 CNN 和 RNN 等判别模型,在样本质量不佳时判别精度下降以及无法满足数据样本生成需求的应用瓶颈。研究人员针对具体的电力系统应用场景需求,主要在神经网络结构、模型网络结构与目标函数等方面对 GAN 进行改进衍生,并将 GAN 与长短期记忆神经网络、自编码神经网络等其他人工智能方法相结合,进一步提升数据特征挖掘的精度与样本生成的准确度。尽管目前已有大量 GAN 模型应用于电力系统领域,但仍有一些问题有待进一步解决:

1) GAN 网络结构与目标函数的优化方法。由于 GAN 的可解释性较差,且 GAN 的性能很大程度上取决于生成器和判别器的神经网络结构和目标函数等,在不同的应用场景下,难以确定 GAN 最优网络结构与目标函数的问题凸显。目前尚未有可以共同遵循的网络结构优化准则,且尚未有统一的评估方式来分析 GAN 神经网络结构与目标函数对模型性能的影响,因此,针对某个具体问题所设计的神经网络结构并不一定是最优结构,目标函数也并不一定是最优的。所以,如何依据电力系统的实际问题 and 已有的数据,对 GAN 网络结构和目标函数进行优化,是一个有待进一步研究的科学问题。

2) GAN 应用效果的统一评价方法。当评价 GAN 在电力系统领域中的应用效果时,研究人员通常将 GAN 生成的电力数据或图像样本,与所对应的真实电力数据或图像样本进行比对,采用各类机器学习数据统计指标或图像质量评价指标,评估

生成样本的准确性,分析其与真实样本的误差;另一方面,研究人员通常依据具体应用需求及先验经验,选择数据统计指标或图像质量评价指标。因此,针对某一类 GAN 衍生模型或某一类具体应用,尚未有统一的评价指标,导致分析 GAN 应用效果时,出现评价标准参差不齐、不一致的问题。所以,如何针对具体的 GAN 模型或者电力系统的应用需求,构建统一的 GAN 性能评价指标,是另一个有待进一步研究的科学问题。

3) GAN 数据增强方面。当前 GAN 应用于电力图像增强的方式主要为图像局部高清化或简单的样本扩充,面对更为复杂的如轮廓锯齿、色彩不平衡等电力图像质量问题时,尚未有良好的解决方案;且当已有数据样本极度匮乏时,GAN 无法很好地挖掘数据特征,存在数据增强效果不理想的问题。因此,如何改进 GAN 或将 GAN 与其他深度学习模型相结合,提升 GAN 的特征提取能力,强化 GAN 对于图像样本的增强能力,解决更为复杂的图像质量问题,是数据增强方面的一个科学问题。

4) GAN 数据生成方面。GAN 模型的输入数据形式为一维向量或多维矩阵,这使得 GAN 在原始电力数据样本不是向量或矩阵形式时,无法学习并提取数据特征,难以解决相应的电力系统工程问题。目前有学者针对这一问题展开初步的研究,如将后备保护的定值配合对转化成矩阵形式<sup>[77]</sup>,将电压暂降的三相电压转换为二维轨迹曲线<sup>[78]</sup>等。因此,针对非向量或矩阵形式的原始电力数据,如何根据要解决的实际工程问题以及原始电力数据特点,构造对应的一维向量或多维矩阵训练集,使得 GAN 能够学习并挖掘相关数据特征,这也是数据生成方面的一个科学问题。

## 参考文献

- [1] 薛禹胜,赖业宁.大能源思维与大数据思维的融合(二)应用及探索[J].电力系统自动化,2016,40(8): 1-13. XUE Yusheng, LAI Yening. Integration of macro energy thinking and big data thinking part two applications and explorations[J]. Automation of Electric Power Systems, 2016, 40(8): 1-13(in Chinese).
- [2] 周念成,廖建权,王强钢,等.深度学习在智能电网中的应用现状分析与展望[J].电力系统自动化,2019,43(4): 180-191. ZHOU Niancheng, LIAO Jianquan, WANG Qianggang, et al. Analysis and prospect of deep learning application in



- smart grid[J]. Automation of Electric Power Systems, 2019, 43(4): 180-191(in Chinese).
- [3] 张怡, 张恒旭, 李常刚, 等. 深度学习在电力系统频率分析与控制中的应用综述[J]. 中国电机工程学报, 2021, 41(10): 3392-3406.
- ZHANG Yi, ZHANG Hengxu, LI Changgang, et al. Review on deep learning applications in power system frequency analysis and control[J]. Proceedings of the CSEE, 2021, 41(10): 3392-3406(in Chinese).
- [4] 孙珂, 赵鹏飞, 韩晓男, 等. 考虑高比例可再生能源出力不确定性的电力流规划方法[J]. 电网技术, 2020, 44(1): 79-85.
- SUN Ke, ZHAO Pengfei, HAN Xiaonan, et al. Electricity flow planning method for high penetration of renewable energy[J]. Power System Technology, 2020, 44(1): 79-85(in Chinese).
- [5] HU Wei, ZHANG Hongxuan, DONG Yu, et al. Short-term optimal operation of hydro-wind-solar hybrid system with improved generative adversarial networks[J]. Applied Energy, 2019, 250: 389-403.
- [6] 尚宇炜, 郭剑波, 吴文传, 等. 电力脑初探: 一种多模式自适应学习系统[J]. 中国电机工程学报, 2018, 38(11): 3133-3143.
- SHANG Yuwei, GUO Jianbo, WU Wenchuan, et al. Preliminary study of electric power brain: a multimodal adaptive learning system[J]. Proceedings of the CSEE, 2018, 38(11): 3133-3143(in Chinese).
- [7] 张宇航, 邱才明, 杨帆, 等. 深度学习在电网图像数据及时空数据中的应用综述[J]. 电网技术, 2019, 43(6): 1865-1873.
- ZHANG Yuhang, QIU Caiming, YANG Fan, et al. Overview of application of deep learning with image data and spatio-temporal data of power grid[J]. Power System Technology, 2019, 43(6): 1865-1873(in Chinese).
- [8] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning[M]. Cambridge: MIT Press, 2016.
- [9] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-Based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [10] GRAVES A, FERNÁNDEZ S, SCHMIDHUBER J. Multi-dimensional recurrent neural networks[C]//Proceedings of the 17th International Conference on Artificial Neural Networks. Porto: Springer, 2007: 549-558.
- [11] GRAVES A. Long short-term memory[M]//GRAVES A. Supervised Sequence Labelling with Recurrent Neural Networks. Berlin: Springer, 2012: 37-45.
- [12] 张东霞, 苗新, 刘丽平, 等. 智能电网大数据技术发展研究[J]. 中国电机工程学报, 2015, 35(1): 2-12.
- ZHANG Dongxia, MIAO Xin, LIU Liping, et al. Research on development strategy for smart grid big data[J]. Proceedings of the CSEE, 2015, 35(1): 2-12(in Chinese).
- [13] 宋亚奇, 周国亮, 朱永利. 智能电网大数据处理技术现状与挑战[J]. 电网技术, 2013, 37(4): 927-935.
- SONG Yaqi, ZHOU Guoliang, ZHU Yongli. Present status and challenges of big data processing in smart grid[J]. Power System Technology, 2013, 37(4): 927-935(in Chinese).
- [14] 薛禹胜, 赖业宁. 大能源思维与大数据思维的融合(一) 大数据与电力大数据[J]. 电力系统自动化, 2016, 40(1): 1-8.
- XUE Yusheng, LAI Yening. Integration of macro energy thinking and big data thinking part one big data and power big data[J]. Automation of Electric Power Systems, 2016, 40(1): 1-8(in Chinese).
- [15] ARBIB M A. The handbook of brain theory and neural networks: second edition[M]. Cambridge: The MIT Press, 2002.
- [16] KINGMA D P, WELING M. Auto-encoding variational bayes[J]. arXiv preprint arXiv: 1312.6114, 2013.
- [17] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [18] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. Montreal: MIT Press, 2014: 2672-2680.
- [19] 陈佛计, 朱枫, 吴清潇, 等. 生成对抗网络及其在图像生成中的应用研究综述[J]. 计算机学报, 2021, 44(2): 347-369.
- CHEN Foji, ZHU Feng, WU Qingxiao, et al. A survey about image generation with generative adversarial nets[J]. Chinese Journal of Computers, 2021, 44(2): 347-369(in Chinese).
- [20] 彭小圣, 邓迪元, 程时杰, 等. 面向智能电网应用的电力大数据关键技术[J]. 中国电机工程学报, 2015, 35(3): 503-511(in Chinese).
- PENG Xiaosheng, DENG Diyu, CHENG Shijie, et al. Key technologies of electric power big data and its application prospects in smart grid[J]. Proceedings of the CSEE, 2015, 35(3): 503-511(in Chinese).
- [21] RATLIFF L J, BURDEN S A, SASTRY S S. Characterization and computation of local Nash equilibria in continuous games[C]//Proceedings of the 51st Annual Allerton Conference on Communication, Control, and Computing(Allerton). Monticello: IEEE, 2013.
- [22] 曹仰杰, 贾丽丽, 陈永霞, 等. 生成式对抗网络及其计算机视觉应用研究综述[J]. 中国图象图形学报, 2018, 23(10): 1433-1449.
- CAO Yangjie, JIA Lili, CHEN Yongxia, et al. Review of

- computer vision based on generative adversarial networks[J]. Journal of Image and Graphics, 2018, 23(10): 1433-1449(in Chinese).
- [23] 王坤峰, 苟超, 段艳杰, 等. 生成式对抗网络 GAN 的研究进展与展望[J]. 自动化学报, 2017, 43(3): 321-332. WANG Kunfeng, GOU Chao, DUAN Yanjie, et al. Generative adversarial networks: the state of the art and beyond[J]. Acta Automatica Sinica, 2017, 43(3): 321-332(in Chinese).
- [24] LI J W, MONROE W, SHI T L, et al. Adversarial learning for neural dialogue generation[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen: Association for Computational Linguistics, 2017.
- [25] YU Lantao, ZHANG Weinan, WANG Jun, et al. SeqGAN: sequence generative adversarial nets with policy gradient[C]//Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence. San Francisco: AAAI, 2016.
- [26] HU Weiwei, TAN Ying. Generating adversarial malware examples for black-box attacks based on GAN[J]. arXiv preprint arXiv: 1702.05983, 2017.
- [27] CHIDAMBARAM M, QI Yanjun. Style transfer generative adversarial networks: learning to play chess differently[J]. arXiv preprint arXiv: 1702.06762, 2017.
- [28] SALIMANS T, GOODFELLOW I, ZAREMBA W, et al. Improved techniques for training GANs[C]//Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona: Curran Associates Inc., 2016.
- [29] MIRZA M, OSINDERO S. Conditional generative adversarial nets[J]. arXiv preprint arXiv: 1411.1784, 2014.
- [30] RADFORD A, METZ L, CHINTALA S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv: 1511.06434, 2016.
- [31] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein GAN[J]. arXiv preprint arXiv: 1701.07875, 2017.
- [32] GULRAJANI I, AHMED F, ARJOVSKY M, et al. Improved training of Wasserstein GANs[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates Inc., 2017.
- [33] ZEILER M D, TAYLOR G W, FERGUS R. Adaptive deconvolutional networks for mid and high level feature learning[C]//Proceedings of 2011 International Conference on Computer Vision. Barcelona: IEEE, 2011.
- [34] NAIR V, HINTON G E. Rectified linear units improve restricted Boltzmann machines[C]//Proceedings of the 27th International Conference on International Conference on Machine Learning. Haifa: Omnipress, 2010.
- [35] XU Bing, WANG Naiyan, CHEN Tianqi, et al. Empirical evaluation of rectified activations in convolutional network[J]. arXiv preprint arXiv: 1505.00853, 2015.
- [36] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C]//Proceedings of the 32nd International Conference on Machine Learning. Lille: JMLR.org, 2015.
- [37] 杨东升, 吉明佳, 周博文, 等. 基于双生成器生成对抗网络的电力系统暂态稳定评估方法[J]. 电网技术, 2021, 45(8): 2934-2944. YANG Dongsheng, JI Mingjia, ZHOU Bowen, et al. Transient stability assessment of power system based on DGL-GAN[J]. Power System Technology, 2021, 45(8): 2934-2944(in Chinese).
- [38] 谭本东, 杨军, 赖秋频, 等. 基于改进 CGAN 的电力系统暂态稳定评估样本增强方法[J]. 电力系统自动化, 2019, 43(1): 149-157. TAN Bendong, YANG Jun, LAI Qiupin, et al. Data augment method for power system transient stability assessment based on improved conditional generative adversarial network[J]. Automation of Electric Power Systems, 2019, 43(1): 149-157(in Chinese).
- [39] 廖一帆, 武志刚. 基于迁移学习与 Wasserstein 生成对抗网络的静态电压稳定临界样本生成方法[J]. 电网技术, 2021, 45(9): 3722-3728. LIAO Yifan, WU Zhigang. Critical sample generation method for static voltage stability based on transfer learning and Wasserstein generative adversarial network[J]. Power System Technology, 2021, 45(9): 3722-3728(in Chinese).
- [40] 关慧哲, 陈颖, 黄少伟, 等. 基于生成对抗网络的暂态稳定预防控制[J]. 电力系统自动化, 2020, 44(24): 36-43. GUAN Huizhe, CHEN Ying, HUANG Shaowei, et al. Preventive control for transient stability based on generative adversarial network[J]. Automation of Electric Power Systems, 2020, 44(24): 36-43(in Chinese).
- [41] 朱永利, 张翼, 蔡炜豪, 等. 基于辅助分类-边界平衡生成式对抗网络的局部放电数据增强与多源放电识别[J]. 中国电机工程学报, 2021, 41(14): 5044-5053. ZHU Yongli, ZHANG Yi, CAI Weihao, et al. Data augmentation and pattern recognition for multi-sources partial discharge based on boundary equilibrium generative adversarial network with auxiliary classifier[J]. Proceedings of the CSEE, 2021, 41(14): 5044-5053(in Chinese).
- [42] 刘云鹏, 许自强, 和家慧, 等. 基于条件式 Wasserstein 生成对抗网络的电力变压器故障样本增强技术[J]. 电网技术, 2020, 44(4): 1505-1513.

- LIU Yunpeng, XU Ziqiang, HE Jiahui, et al. Data augmentation method for power transformer fault diagnosis based on conditional Wasserstein generative adversarial network[J]. Power System Technology, 2020, 44(4): 1505-1513(in Chinese).
- [43] 李雅欣, 侯慧娟, 胥明凯, 等. 基于策略梯度和生成式对抗网络的变压器油色谱案例扩充方法[J]. 电力自动化设备, 2020, 40(12): 211-217.
- LI Yaxin, HOU Huijuan, XU Mingkai, et al. Oil chromatogram case generation method of transformer based on policy gradient and generative adversarial networks[J]. Electric Power Automation Equipment, 2020, 40(12): 211-217(in Chinese).
- [44] 黄南天, 杨学航, 蔡国伟, 等. 采用非平衡小样本数据的风机主轴承故障深度对抗诊断[J]. 中国电机工程学报, 2020, 40(2): 563-573.
- HUANG Nantian, YANG Xuehang, CAI Guowei, et al. A deep adversarial diagnosis method for wind turbine main bearing fault with imbalanced small sample scenarios[J]. Proceedings of the CSEE, 2020, 40(2): 563-573(in Chinese).
- [45] 卢锦玲, 张祥国, 张伟, 等. 基于改进辅助分类生成对抗网络的风机主轴承故障诊断[J]. 电力系统自动化, 2021, 45(7): 148-154.
- LU Jinling, ZHANG Xiangguo, ZHANG Wei, et al. Fault diagnosis of main bearing of wind turbine based on improved auxiliary classifier generative adversarial network[J]. Automation of Electric Power Systems, 2021, 45(7): 148-154(in Chinese).
- [46] 金晓航, 许壮伟, 孙毅, 等. 基于生成对抗网络的风电机组在线状态监测[J]. 仪器仪表学报, 2020, 41(4): 68-76.
- JIN Xiaohang, XU Zhuangwei, SUN Yi, et al. Online condition monitoring of wind turbine based on generative adversarial network[J]. Chinese Journal of Scientific Instrument, 2020, 41(4): 68-76(in Chinese).
- [47] YUAN Yuxuan, DEHGHANPOUR K, BU Fankun, et al. Outage detection in partially observable distribution systems using smart meters and generative adversarial networks[J]. IEEE Transactions on Smart Grid, 2020, 11(6): 5418-5430.
- [48] 袁培, 王舶仲, 毛文奇, 等. 基于多重生成对抗网络的智能开关设备状态感知与诊断研究[J]. 电力系统保护与控制, 2021, 49(6): 67-75.
- YUAN Pei, WANG Bozhong, MAO Wenqi, et al. Research on state perception and diagnosis of intelligent switches based on triple generative adversarial networks [J]. Power System Protection and Control, 2021, 49(6): 67-75(in Chinese).
- [49] 王德文, 李业东. 基于 WGAN 图片去模糊的绝缘子目标检测[J]. 电力自动化设备, 2020, 40(5): 188-194.
- WANG Dewen, LI Yedong. Insulator object detection based on image deblurring by WGAN[J]. Electric Power Automation Equipment, 2020, 40(5): 188-194(in Chinese).
- [50] 黄文琦, 许爱东, 明哲, 等. 基于生成对抗网络的变电站工作人员行为预测的方法[J]. 南方电网技术, 2019, 13(2): 45-50.
- HUANG Wenqi, XU Aidong, MING Zhe, et al. Prediction method for the behavior of substation staff based on generative adversarial network[J]. Southern Power System Technology, 2019, 13(2): 45-50(in Chinese).
- [51] 李皎, 郭鹏. 基于 ARGAN 表面阴影预处理与迁移学习的风电机叶片故障识别[J]. 华北电力大学学报, 2021, 48(2): 73-79.
- LI Jiao, GUO Peng. ARGAN-based surface shadow preprocessing and transfer learning fault identification of wind turbine blade[J]. Journal of North China Electric Power University, 2021, 48(2): 73-79(in Chinese).
- [52] 杨剑锋, 秦钟, 庞小龙, 等. 基于深度神经网络的输电线路异物入侵监测和识别方法[J]. 电力系统保护与控制, 2021, 49(4): 37-44.
- YANG Jianfeng, QIN Zhong, PANG Xiaolong, et al. Foreign body intrusion monitoring and recognition method based on Dense-YOLOv3 deep learning network[J]. Power System Protection and Control, 2021, 49(4): 37-44(in Chinese).
- [53] 王守相, 陈海文, 潘志新, 等. 采用改进生成式对抗网络的电力系统量测缺失数据重建方法[J]. 中国电机工程学报, 2019, 39(1): 56-64.
- WANG Shouxiang, CHEN Haiwen, PAN Zhixin, et al. A reconstruction method for missing data in power system measurement using an improved generative adversarial network[J]. Proceedings of the CSEE, 2019, 39(1): 56-64(in Chinese).
- [54] REN Chao, XU Yan. A fully data-driven method based on generative adversarial networks for power system dynamic security assessment with missing data[J]. IEEE Transactions on Power Systems, 2019, 34(6): 5044-5052.
- [55] 王德文, 杨凯华. 基于生成式对抗网络的窃电检测数据生成方法[J]. 电网技术, 2020, 44(2): 775-782.
- WANG Dewen, YANG Kaihua. A data generation method for electricity theft detection using generative adversarial network[J]. Power System Technology, 2020, 44(2): 775-782(in Chinese).
- [56] 杨玉莲, 齐林海, 王红, 等. 基于生成对抗和双重语义感知的配电网量测数据缺失重构[J]. 电力系统自动化, 2020, 44(18): 46-54.
- YANG Yulian, QI Linhai, WANG Hong, et al. Reconstruction of missing measurement data in

- distribution network based on generative adversarial network and double semantic perception[J]. Automation of Electric Power Systems, 2020, 44(18): 46-54(in Chinese).
- [57] 张承圣, 邵振国, 陈飞雄, 等. 基于条件深度卷积生成对抗网络的新能源发电场景数据迁移方法[J]. 电网技术, 2022, 46(06): 2182-2190.  
ZHANG Chengsheng, SHAO Zhenguo, CHEN Feixiong, et al. A renewable power generation data transferring method based on conditional deep convolutions generative adversarial network[J]. Power System Technology, 2022, 46(06): 2182-2190(in Chinese).
- [58] LI Fusheng, LIN Dan, YU Tao. Improved generative adversarial network-based super resolution reconstruction for low-frequency measurement of smart grid[J]. IEEE Access, 2020, 8: 85257-85270.
- [59] ZHANG Chengsheng, SHAO Zhenguo, JIANG Changxu, et al. A PV generation data reconstruction method based on improved super-resolution generative adversarial network[J]. International Journal of Electrical Power & Energy Systems, 2021, 132: 107129.
- [60] TANG Rui, DORE J, MA Jin, et al. Interpolating high granularity solar generation and load consumption data using super resolution generative adversarial network[J]. Applied Energy, 2021, 299: 117297.
- [61] 肖白, 黄钰茹, 姜卓, 等. 数据匮乏场景下采用生成对抗网络的空间负荷预测方法[J]. 中国电机工程学报, 2020, 40(24): 7990-8001.  
XIAO Bai, HUANG Yuru, JIANG Zhuo, et al. The method of spatial load forecasting based on the generative adversarial network for data scarcity scenarios[J]. Proceedings of the CSEE, 2020, 40(24): 7990-8001(in Chinese).
- [62] 林珊, 王红, 齐林海, 等. 基于条件生成对抗网络的短期负荷预测[J]. 电力系统自动化, 2021, 45(11): 52-60.  
LIN Shan, WANG Hong, QI Linhai, et al. Short-term load forecasting based on conditional generative adversarial network[J]. Automation of Electric Power Systems, 2021, 45(11): 52-60(in Chinese).
- [63] ZHOU Bin, DUAN Haoran, WU Qiuwei, et al. Short-term prediction of wind power and its ramp events based on semi-supervised generative adversarial network[J]. International Journal of Electrical Power & Energy Systems, 2021, 125: 106411.
- [64] EL KABABJI S, SRIKANTHA P. A data-driven approach for generating synthetic load patterns and usage habits[J]. IEEE Transactions on Smart Grid, 2020, 11(6): 4984-4995.
- [65] WANG Hong, QI Linhai, YAN Lei, et al. Load photo: a novel analysis method for load data[J]. IEEE Transactions on Smart Grid, 2021, 12(2): 1394-1404.
- [66] 吴钉捷, 李晓露, 陆一鸣. 基于生成对抗网络和联邦学习的非侵入式负荷分解方法[J]. 电测与仪表, 2022, 59(6): 37-45.  
WU Dingjie, LI Xiaolu, LU Yiming. Non-intrusive load disaggregation method based on GAN and federated learning[J]. Electrical Measurement & Instrumentation, 2022, 59(6): 37-45(in Chinese).
- [67] CHEN Yize, WANG Yishen, KIRSCHEN D, et al. Model-free renewable scenario generation using generative adversarial networks[J]. IEEE Transactions on Power Systems, 2018, 33(3): 3265-3275.
- [68] 董晓翀, 孙英云, 蒲天骄. 基于条件生成对抗网络的可再生能源日前场景生成方法[J]. 中国电机工程学报, 2020, 40(17): 5527-5535.  
DONG Xiaochong, SUN Yingyun, PU Tianjiao. Day-ahead scenario generation of renewable energy based on conditional GAN[J]. Proceedings of the CSEE, 2020, 40(17): 5527-5535(in Chinese).
- [69] ZHANG Yufan, AI Qian, XIAO Fei, et al. Typical wind power scenario generation for multiple wind farms using conditional improved Wasserstein generative adversarial network[J]. International Journal of Electrical Power & Energy Systems, 2020, 114: 105388.
- [70] 李辉, 任洲洋, 胡博, 等. 基于时序生成对抗网络的月度风光发电功率场景分析方法[J]. 中国电机工程学报, 2022, 42(2): 537-547.  
LI Hui, REN Zhouyang, HU Bo, et al. A sequential generative adversarial network based monthly scenario analysis method for wind and photovoltaic power[J]. Proceedings of the CSEE, 2022, 42(2): 537-547(in Chinese).
- [71] 张文强, 陈静, 杨伟, 等. 基于VAE-CGAN的光伏不确定性建模方法[J]. 电网技术, 2021, 45(4): 1273-1279.  
ZHANG Wenqiang, CHEN Jing, YANG Wei, et al. Photovoltaic uncertainty modeling based on VAE-CGAN[J]. Power System Technology, 2021, 45(4): 1273-1279(in Chinese).
- [72] 李康平, 张展耀, 王飞, 等. 基于GAN场景模拟与条件风险价值的独立型微网容量随机优化配置模型[J]. 电网技术, 2019, 43(5): 1717-1725.  
LI Kangping, ZHANG Zhanyao, WANG Fei, et al. Stochastic optimization model of capacity configuration for stand-alone microgrid based on scenario simulation using GAN and conditional value at risk[J]. Power System Technology, 2019, 43(5): 1717-1725(in Chinese).
- [73] 顾洁, 刘书琪, 胡玉, 等. 基于深度卷积生成对抗网络场景生成的间歇式分布式电源优化配置[J]. 电网技术, 2021, 45(5): 1742-1749.  
GU Jie, LIU Shuqi, HU Yu, et al. Optimal allocation of



- intermittent distributed generation based on deep convolutions generative adversarial network in scenario generation[J]. Power System Technology, 2021, 45(5): 1742-1749(in Chinese).
- [74] 马燕峰, 傅钰, 赵书强, 等. 基于 WGAN 风光资源场景模拟和时序生产模拟的新能源电源容量配置[J]. 电力自动化设备, 2020, 40(11): 77-84.  
MA Yanfeng, FU Yu, ZHAO Shuqiang, et al. Capacity allocation of new energy source based on wind and solar resource scenario simulation using WGAN and sequential production simulation[J]. Electric Power Automation Equipment, 2020, 40(11): 77-84(in Chinese).
- [75] LI Yang, LI Jiazheng, WANG Yi. Privacy-preserving spatiotemporal scenario generation of renewable energies: a federated deep generative learning approach[J]. IEEE Transactions on Industrial Informatics, 2022, 18(4): 2310-2320, doi: 10.1109/TII.2021.3098259.
- [76] 肖白, 于龙泽, 刘洪波, 等. 基于生成虚拟净负荷的多能源电力系统日前优化调度[J]. 中国电机工程学报, 2021, 41(21): 7237-7248.  
XIAO Bai, YU Longze, LIU Hongbo, et al. Day ahead optimal dispatch of multi-energy power system based on generating virtual net load[J]. Proceedings of the CSEE, 2021, 41(21): 7237-7248(in Chinese).
- [77] 凌谢津, 李银红. 基于生成对抗网络的后备保护在线整定快速计算方案[J]. 中国电机工程学报, 2021, 41(13): 4439-4449.  
LING Xiejin, LI Yin hong. Quick calculation scheme of backup protection online setting based on generative adversarial networks[J]. Proceedings of the CSEE, 2021, 41(13): 4439-4449(in Chinese).
- [78] 沙浩源, 梅飞, 李丹奇, 等. 基于改进生成对抗网络的电压暂降事件类型辨识研究[J]. 中国电机工程学报, 2021, 41(22): 7648-7659.  
SHA Haoyuan, MEI Fei, LI Danqi, et al. Research on voltage sag event type identification based on improved generative adversarial networks[J]. Proceedings of the CSEE, 2021, 41(22): 7648-7659(in Chinese).



邵振国

在线出版日期: 2022-05-31。

收稿日期: 2021-10-21。

作者简介:

邵振国(1970), 男, 教授, 博士生导师, 研究方向为电网不确定性理论与方法、电能质量分析与治理、电力大数据理论与方法等, shao.zg@fzu.edu.cn;

张承圣(1997), 男, 硕士研究生, 研究方向为电力大数据理论与方法, cristiano\_mule@163.com;

陈飞雄(1990), 男, 博士, 讲师, 研究方向为综合能源系统协同控制方法, 电力大数据分析挖掘技术等, feixiongchen@fzu.edu.cn;

谢雨寒(1998), 男, 硕士研究生, 研究方向为电力大数据理论与方法, xyh\_0107\_2017@163.com。

(责任编辑 乔宝榆)

# A Review on Generative Adversarial Networks for Power System Applications

SHAO Zhenguo\*, ZHANG Chengsheng, CHEN Feixiong, XIE Yuhan  
(Fujian Smart Electrical Engineering Technology Research Center  
(College of Electrical Engineering and Automation), Fuzhou University)

**KEY WORDS:** deep learning; generative adversarial network; power system; data enhancement; data generation

In recent years, due to the rapid development of renewable energy, modern power systems have exhibited new features and forms, which include the explosive growth of power data scale. In view of massive, multi-source and multi-dimensional complex power data, one of the significant technical issues faced by the modern power system is how to efficiently utilize the power data. The deep learning algorithm, which can be regarded as a new generation of artificial intelligence technology, has unique advantages in dimensionality reduction, non-linear fitting and feature extraction. Among the deep learning algorithms, the generative adversarial network (GAN) has a brilliant performance in power data enhancement and generation. Therefore, this paper reviewed GAN for power system applications.

First, this paper introduced the fundamental theory of GAN by analyzing its advantages and disadvantages.

Secondly, four GAN derivative models that are widely applied to power systems were summarized from the perspective of the network structure and the objective function.

Then, the applications of GAN in power systems were reviewed in detail, as shown in Fig. 1. By this means, the GAN model used in each application scenario was introduced in the view of two requirements, which include power data enhancement and generation. The characteristics of GAN in each application scenario were analyzed and the applications of GAN in data enhancement and generation were summarized. Besides, the situation of GAN was reviewed in this paper from the perspective of GAN derived models.

Finally, this paper outlined the potential research directions and attempted to shed light on the deeper and broader applications of GAN in the power system..

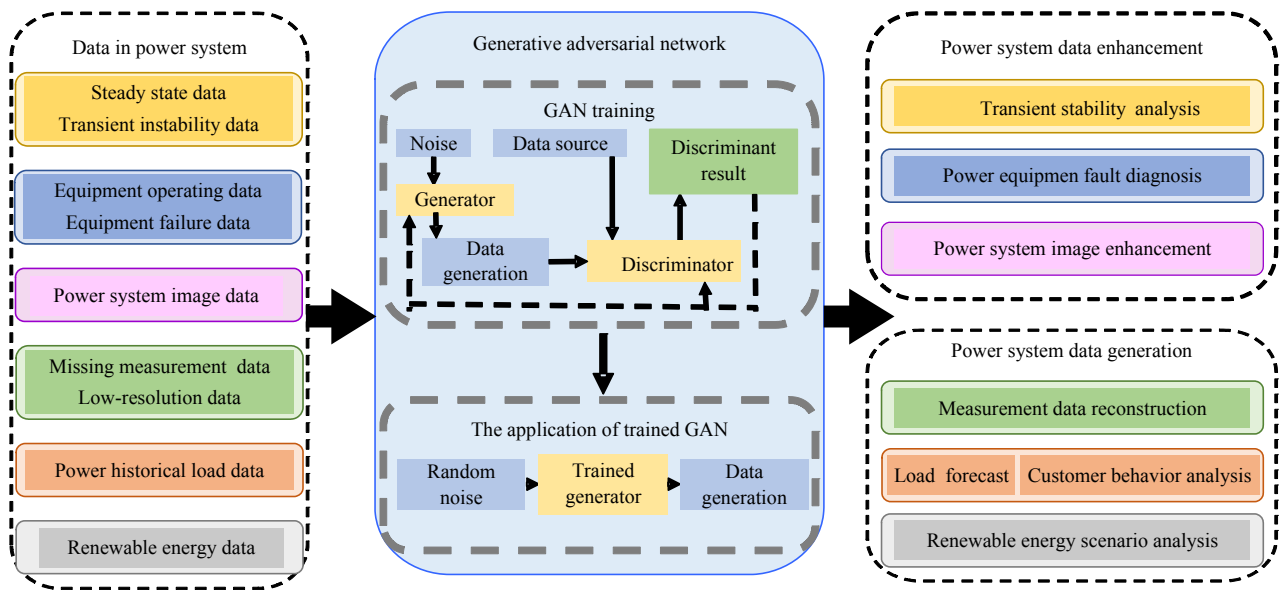


Fig. 1 Overview of GAN for power systems applications